



**UNIVERSIDADE DE FORTALEZA
CENTRO DE CIÊNCIAS TECNOLÓGICAS
CURSO DE GRADUAÇÃO EM CIÊNCIA DA COMPUTAÇÃO**

NICHOLAS MESQUITA CABRAL DOS ANJOS

**ANÁLISE DE DESEMPENHO DE ALGORITMOS DE COMPRESSÃO DE IMAGENS
EM AMBIENTES HOSPITALARES**

FORTALEZA – CEARÁ

2024

NICHOLAS MESQUITA CABRAL DOS ANJOS

**ANÁLISE DE DESEMPENHO DE ALGORITMOS DE COMPRESSÃO DE IMAGENS EM
AMBIENTES HOSPITALARES**

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à
obtenção do grau de bacharel em Ciência da Computação.

Orientador: Prof. Dr. Napoleão Vieira
Nepomuceno

FORTALEZA – CEARÁ

2024

A ficha catalográfica deve ser gerada no site da biblioteca da Unifor através do link <https://goo.gl/XYUWSC> (link encurtado).

Preencha o formulário com as informações solicitadas e ao final será gerado um arquivo PDF da ficha catalográfica a ser anexada na versão final do TCC.

O arquivo PDF deve ser renomeado para "ficha-catalografica.pdf" (sem aspas) e colocado no diretório "elementos-pre-textuais" (sem aspas) do modelo de TCC da Unifor.

Ficha catalográfica da obra elaborada pelo autor através do programa de geração automática da Biblioteca Central da Universidade de Fortaleza

Batista, Bruno .

TEORIA DA RELATIVIDADE: SUBTÍTULO / Bruno Batista, Sandra Lima. - 2017
40 f.

Trabalho de Conclusão de Curso (Graduação) - Universidade de Fortaleza. Curso de Ciência da Computação, Fortaleza, 2017.
Orientação: Liadina Camargo.

1. FÍSICA. 2. RELATIVIDADE. 3. TEMPO. 4. ESPAÇO. I. Lima, Sandra. II. Camargo, Liadina. III. Título.

NICHOLAS MESQUITA CABRAL DOS ANJOS

ANÁLISE DE DESEMPENHO DE ALGORITMOS DE COMPRESSÃO DE IMAGENS EM
AMBIENTES HOSPITALARES

Trabalho de Conclusão de Curso apresentado ao
Curso de Graduação em Ciência da Computação
do Centro de Ciências Tecnológicas da Universidade de Fortaleza, como requisito parcial à
obtenção do grau de bacharel em Ciência da Computação.

Aprovada em: 01 de Dezembro de 2020

BANCA EXAMINADORA

Prof. Dr. Napoleão Vieira Nepomuceno (Orientador)
Centro de Ciências Tecnológicas - CCT
Universidade de Fortaleza - UNIFOR

Membro da Banca Dois
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Dois - SIGLA

Membro da Banca Três
Centro de Ciências e Tecnologia - CCT
Universidade do Membro da Banca Três - SIGLA

Aos meus pais. Klauber e Sueli, pelo apoio em
todos os momentos da minha vida.

AGRADECIMENTOS

Gostaria de agradecer primeiramente a Deus, por me guiar ao longo de toda minha trajetória.

Aos meus pais e irmã pelo apoio.

Ao meu orientador Prof. Napoleão Vieira Nepomuceno pelo voto de confiança e pelo auxílio indispensável no desenvolvimento deste trabalho.

À todos os colegas e professores da Graduação em Ciência da Computação que contribuíram para a minha formação acadêmica.

RESUMO

Este estudo investiga a relação entre taxas de compressão e perda de informações em imagens médicas de tomografia no padrão DICOM. Foram utilizados três métodos de compressão: PNG, JPEG e PCA. O objetivo é evidenciar os cenários onde cada método se destaca, conciliando a redução do tamanho das imagens com a preservação da qualidade necessária para fins diagnósticos. O PNG foi avaliado por sua capacidade de compressão sem perdas, garantindo a preservação completa da qualidade visual da imagem. O JPEG foi analisado como uma alternativa de compressão com perdas controláveis, ideal para redução significativa de tamanho com comprometimento aceitável da qualidade. Já o PCA explorou a redução de dimensionalidade, utilizando percentuais de variância explicada para ajustar a compressão conforme a necessidade de retenção de informações. A análise comparativa revelou vantagens e limitações de cada método, destacando como o conteúdo das imagens (como áreas homogêneas ou detalhes finos) influencia os resultados de compressão e qualidade visual. Este estudo contribui para a escolha de estratégias adequadas de compressão em sistemas hospitalares, otimizando o armazenamento de imagens médicas no padrão DICOM.

Palavras-chave: Compressão de Dados. Imagens Médicas. DICOM. Qualidade Visual. Redução de Dimensionalidade. Tomografia Computadorizada.

ABSTRACT

This study investigates the relationship between compression rates and information loss in DICOM-standard medical tomography images. Three compression methods were evaluated: PNG, JPEG, and PCA. The objective is to highlight the scenarios where each method stands out, balancing image size reduction and the preservation of diagnostic quality. PNG was analyzed for its lossless compression capability, ensuring complete preservation of image quality. JPEG was studied as a lossy compression method, suitable for significant size reduction while maintaining acceptable visual quality. PCA explored dimensionality reduction by adjusting compression levels based on the percentage of explained variance, allowing flexibility between compression and information retention. The comparative analysis revealed the advantages and limitations of each method, highlighting how image characteristics (e.g., homogeneous areas or fine details) influence compression results. This study contributes to the selection of efficient compression strategies in hospital systems, optimizing the storage of medical images in the DICOM standard.

Keywords: Data Compression. Medical Images. DICOM. Visual Quality. Dimensionality Reduction. Computed Tomography.

LISTA DE ILUSTRAÇÕES

Figura 1 – Exemplo de compressão de imagem.	18
Figura 2 – Comparação entre diferentes taxas de compressão	19
Figura 3 – Comparação entre compressão com e sem perda	20
Figura 4 – Comparação entre diferentes níveis de quantização	24
Figura 5 – Visualização de uma imagem em escala de cinza e RGB	25
Figura 6 – Metadados de uma imagem DICOM	26
Figura 7 – Visualização de uma imagem DICOM	27
Figura 8 – Árvore de Huffman para uma sequência de caracteres aleatórios	28
Figura 9 – Compressão de imagem com PNG	32
Figura 10 – Fluxo de compressão e descompressão do JPEG	33
Figura 11 – Comparação visual das imagens de pulmão: original e comprimidas por PNG, JPEG e PCA.	48
Figura 12 – Comparação visual das imagens de mama: original e comprimidas por PNG, JPEG e PCA.	49
Figura 13 – Comparação visual das imagens de cérebro: original e comprimidas por PNG, JPEG e PCA.	50
Figura 14 – Taxas médias de compressão por tipo de órgão e método de compressão.	51
Figura 15 – Taxas médias de compressão PNG por tipo de órgão.	52
Figura 16 – Taxas médias de compressão JPEG por tipo de órgão.	52
Figura 17 – Taxas médias de compressão por tipo de órgão para o PCA (95% de variância explicada).	53
Figura 18 – Taxas médias de compressão por tipo de órgão para o PCA (97,5% de variância explicada).	54
Figura 19 – Taxas médias de compressão por tipo de órgão para o PCA (99% de variância explicada).	54
Figura 20 – Valores médios de PSNR por algoritmo e tipo de órgão.	55

LISTA DE QUADROS

Quadro 1 – Resumo detalhado das etapas da metodologia.	46
---	----

LISTA DE ALGORITMOS

Algoritmo 1 – Codificação de Huffman	30
---	----

SUMÁRIO

1	INTRODUÇÃO	14
1.1	DEFINIÇÃO DO PROBLEMA	14
1.2	MOTIVAÇÃO E RELEVÂNCIA	14
1.3	OBJETIVOS	15
1.3.1	Objetivos Específicos	15
1.4	QUESTÕES DE PESQUISA	15
1.5	ORGANIZAÇÃO DO TRABALHO	16
2	FUNDAMENTAÇÃO TEÓRICA	18
2.1	COMPRESSÃO DE DADOS	18
2.1.1	Taxa de compressão	19
2.1.2	Compressão sem perda	19
2.1.3	Compressão com perda	20
2.1.4	Entropia	21
2.1.5	<i>Discrete Cosine Transformation (DCT)</i>	22
2.1.6	Quantização	23
2.1.7	<i>Red, Green, Blue (RGB) vs Escala de cinza (Grayscale)</i>	24
2.2	<i>Digital Imaging and Communications in Medicine (DICOM)</i>	25
2.3	ALGORITMO DE HUFFMAN	27
2.4	ALGORITMOS DE COMPRESSÃO DE IMAGENS	30
2.4.1	<i>Portable Network Graphics (PNG)</i>	30
2.4.2	<i>Joint Photographic Experts Group (JPEG)</i>	33
2.4.3	<i>Principal Component Analysis (PCA)</i>	35
3	TRABALHOS RELACIONADOS	37
3.1	PROCESSOS DE COMPRESSÃO DE DADOS APLICADOS A IMAGENS MÉDICAS	37
3.2	COMPRESSÃO DE IMAGENS MAMOGRÁFICAS UTILIZANDO SEGMENTAÇÃO E O ALGORITMO PPM	37
3.3	UTILIZAÇÃO DA ANÁLISE DE COMPONENTES PRINCIPAIS NA COMPRESSÃO DE IMAGENS DIGITAIS	38
3.4	COMPRESSÃO DE IMAGENS COM TRANSMISSÃO EM TEMPO REAL	39

3.5	PROJETO DE ARQUITETURAS INTEGRADAS PARA A COMPRESSÃO DE IMAGENS JPEG	39
4	METODOLOGIA	41
4.1	BASE DE DADOS	41
4.1.1	Classificação das imagens	41
4.1.2	Transfer Syntax UID	42
4.2	DEFINIÇÃO DOS CENÁRIOS	44
4.2.1	Pré-processamento	44
4.2.2	Processamento	44
4.2.3	Avaliação da Qualidade das Imagens	45
5	RESULTADOS	47
5.1	COMPARAÇÃO VISUAL DAS IMAGENS	47
5.2	TAXAS DE COMPRESSÃO	50
5.3	TAXAS DE COMPRESSÃO POR MÉTODO	51
5.3.1	PNG	51
5.3.2	JPEG	52
5.3.3	PCA	53
5.4	ANÁLISE DE QUALIDADE APARENTE (PSNR)	54
5.5	DISCUSSÃO DOS RESULTADOS	55
6	CONCLUSÃO	57
	REFERÊNCIAS	59

1 INTRODUÇÃO

No âmbito da medicina, a obtenção e preservação de imagens de tomografia são desafios prementes. Por serem algo fundamental para os processos de análises radiológicas, é imprescindível que essas imagens tenham boa nitidez e praticidade de armazenamento. Com isso, a adoção do formato *Digital Imaging and Communications in Medicine* (DICOM) (NEMA, 2016) como padrão internacional de imagens médicas aprimorou a forma como os hospitais lidam com as tomografias. O uso dessas imagens no cenário hospitalar, onde a complexidade dessas pode variar amplamente, resulta em arquivos que, em escala, podem sobrecarregar os sistemas de armazenamento dos hospitais. Este estudo compara métodos de compressão modernos para identificar formas eficientes de se armazenar essas imagens em diferentes cenários.

1.1 DEFINIÇÃO DO PROBLEMA

A problemática essencial reside no gerenciamento eficaz de dados em ambientes hospitalares, onde várias tomografias são armazenadas, o que pode gerar um impacto substancial à infraestrutura digital dos hospitais. O volume crescente de dados gerados diariamente requer uma abordagem adaptativa para mitigar os desafios associados ao armazenamento e ao custo monetário elevado. Este estudo procura evidenciar como diferentes métodos de compressão performam em diferentes cenários, destacando suas vantagens e limitações, com o objetivo de compreender o impacto na integridade dos dados e auxiliar na escolha adequada para diferentes contextos de armazenamento.

1.2 MOTIVAÇÃO E RELEVÂNCIA

Este estudo é motivado pela necessidade de avaliar como diferentes métodos de compressão podem reduzir eficientemente o tamanho das imagens de tomografia, considerando o impacto na qualidade e identificando o equilíbrio entre compressão e preservação visual, tendo em vista sua importância na prática clínica. A tomografia desempenha um papel fundamental no diagnóstico e monitoramento de diversas condições médicas, e a compressão dessas imagens torna-se crucial para a manutenibilidade da infraestrutura digital dos hospitais. A relevância desta problemática está intrinsecamente ligada à crescente necessidade de tecnologias que melhorem o armazenamento e otimizem os recursos, visando eficiência e redução de custos. Ao comparar abordagens de compressão, temos como objetivo encontrar a forma que consiga conciliar uma

alta taxa de compressão com uma baixa taxa de perda. Este estudo almeja ser uma contribuição para aprimorar a gestão de imagens de tomografia em ambientes hospitalares de grande escala.

1.3 OBJETIVOS

O objetivo geral deste estudo é analisar o desempenho dos métodos de compressão PNG, JPEG e PCA na redução do tamanho de imagens DICOM, considerando diferentes tipos de órgãos (pulmão, mama e cérebro). A análise é realizada por meio da comparação das taxas de compressão e da perda de qualidade, buscando compreender como cada método concilia a redução do tamanho (em bytes) com a preservação da integridade das informações, em diferentes contextos de aplicação.

1.3.1 Objetivos Específicos

1. Obter uma base de dados com imagens de tomografias.
2. Implementar algoritmos modernos de compressão de imagens como *Portable Network Graphics* (PNG), *Joint Photographic Experts Group* (JPEG) e *Principal Component Analysis* (PCA).
3. Realizar um estudo comparativo entre os algoritmos citados acima.
4. Investigar a relação entre as taxas de compressão e perda de qualidade de cada método.
5. Identificar os cenários de armazenamento em que cada um dos métodos de compressão se mostra mais adequado, considerando as necessidades de eficiência no uso de espaço e preservação da qualidade das imagens médicas para diferentes tipos de órgãos.
6. Explicar como cada órgão apresenta diferentes taxas de compressão, destacando as variações no desempenho dos métodos de compressão em função das características específicas de cada imagem.

1.4 QUESTÕES DE PESQUISA

1. Quais são as taxas médias de compressão alcançadas pelos algoritmos PNG, JPEG e PCA em imagens médicas de pulmão, mama e cérebro?
2. Como as características das imagens de cada órgão (pulmão, mama e cérebro) influenciam as taxas de compressão dos algoritmos PNG, JPEG e PCA?
3. Como a variação da taxa de compressão impacta a qualidade visual das imagens de

tomografia, considerando o PSNR como métrica de avaliação?

4. Qual algoritmo oferece o melhor equilíbrio entre compressão e qualidade visual para cada órgão, considerando os resultados de PSNR e taxa de compressão?

1.5 ORGANIZAÇÃO DO TRABALHO

O restante do trabalho está organizado nas seguintes seções:

- No Capítulo 2, são explorados os fundamentos teóricos essenciais da compressão de dados, uma área importante na ciência da computação e na transmissão eficiente de informações. São abordados os dois principais paradigmas de compressão: com perda e sem perda, discutindo os princípios subjacentes, as aplicações relevantes e as métricas comumente usadas para avaliar a eficácia de cada abordagem. O objetivo é fornecer uma base sólida para a análise detalhada dos algoritmos específicos de compressão e sua aplicação no contexto de otimização de imagens médicas.
- No Capítulo 3, são discutidos estudos anteriores e pesquisas relevantes sobre a aplicação de técnicas de compressão de imagens em diferentes cenários, com ênfase no armazenamento de imagens de tomografia. A revisão da literatura existente identifica avanços, desafios e lacunas, contextualizando o estudo dentro do panorama atual da área e justificando a escolha dos algoritmos e metodologias utilizadas.
- No Capítulo 4, são descritas detalhadamente as etapas e procedimentos adotados para a compressão de imagens de tomografia, incluindo a coleta de dados, a implementação dos algoritmos de compressão, a análise comparativa entre eles e a medição da perda de informações. São explicadas as ferramentas e técnicas utilizadas, justificadas as escolhas metodológicas e discutidas as considerações éticas e práticas associadas ao manejo dos dados de tomografia.
- No Capítulo 5, são apresentados os resultados obtidos, incluindo as taxas de compressão e de perda de qualidade alcançadas pelos algoritmos PNG, JPEG e PCA. É analisada a perda de informações associada a cada método e seu impacto na qualidade das imagens, identificando os cenários mais adequados para a aplicação de cada técnica. Os dados obtidos são discutidos de maneira quantitativa e qualitativa, com gráficos e tabelas para ilustrar as descobertas.
- No Capítulo 6, são apresentadas as conclusões finais, resumindo os principais achados e destacando as contribuições do estudo para a área de compressão de dados em imagens

médicas. São discutidas as limitações encontradas durante a pesquisa e sugeridas direções para futuras investigações, com recomendações para o aprimoramento das técnicas de compressão e novas abordagens para a solução dos problemas identificados.

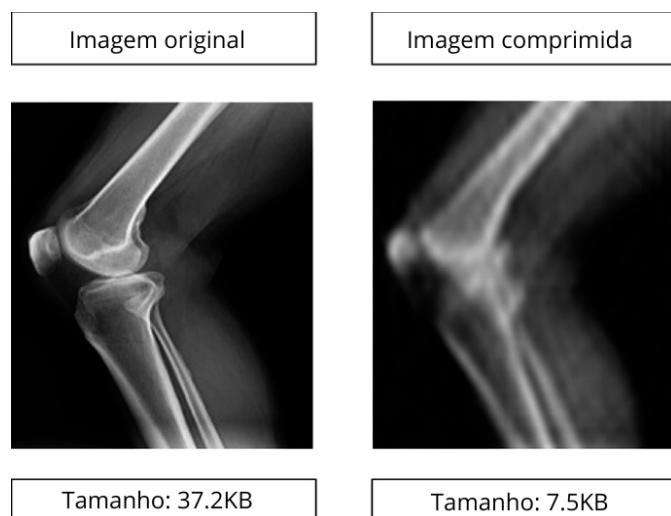
2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, serão explorados os fundamentos teóricos essenciais relacionados à compressão de dados, um campo vital na ciência da computação e na transmissão eficiente de informações. Abordamos os dois principais paradigmas de compressão, com perda e sem perda, discutindo os princípios subjacentes, as aplicações relevantes e as métricas comumente usadas para avaliar a eficácia de cada abordagem. Esses conceitos fundamentais são essenciais para compreender em detalhes os algoritmos específicos de compressão e sua aplicação no contexto prático de otimização de imagens médicas.

2.1 COMPRESSÃO DE DADOS

A compressão de dados é um campo essencial na área da tecnologia da informação que visa reduzir o espaço de armazenamento e a largura de banda necessária para transmissão de informações sem comprometer a integridade dos dados. A Figura 1 ilustra a comparação de tamanho entre uma imagem original e uma imagem comprimida. O primeiro contato significativo com a compressão de dados foi com a codificação de Huffman em 1952 (HUFFMAN, 1952), marco fundamental que estabeleceu as bases teóricas para a eficiente representação de informações.

Figura 1 – Exemplo de compressão de imagem.



Fonte: Adaptada de (CHAUDHARY *et al.*, 2021)

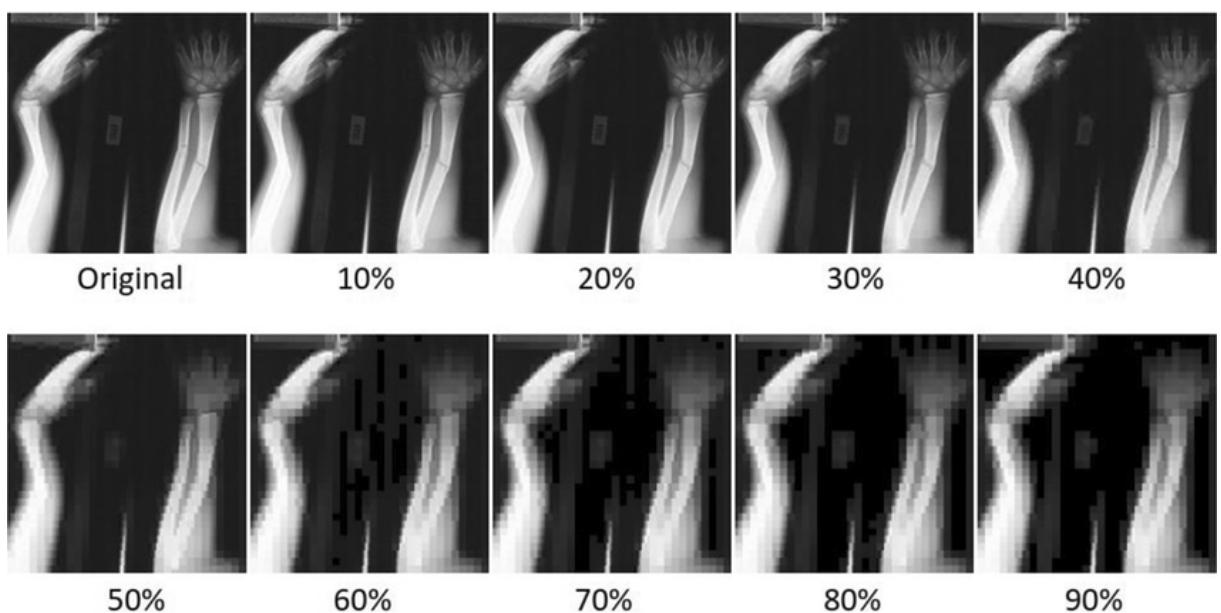
2.1.1 Taxa de compressão

A taxa de compressão, ou do inglês *Compression Rate* (CR), é uma métrica crucial que quantifica a eficiência do processo de compressão. Ela é definida como a razão entre o tamanho do arquivo comprimido ($S_{\text{comprimido}}$) e o tamanho do arquivo original (S_{original}):

$$CR = \frac{S_{\text{comprimido}}}{S_{\text{original}}}$$

A Figura 2 ilustra um exemplo dessa taxa de compressão, no qual é possível perceber que, à medida que a taxa de compressão aumenta, o tamanho do arquivo diminui, resultando em perdas progressivas de qualidade da imagem. Grossso modo isso se da pois quanto mais detalhes uma imagem tem, mais bits são necessários para representar aquela imagem. Isso é evidente na comparação visual entre a imagem original e suas versões comprimidas.

Figura 2 – Comparação entre diferentes taxas de compressão



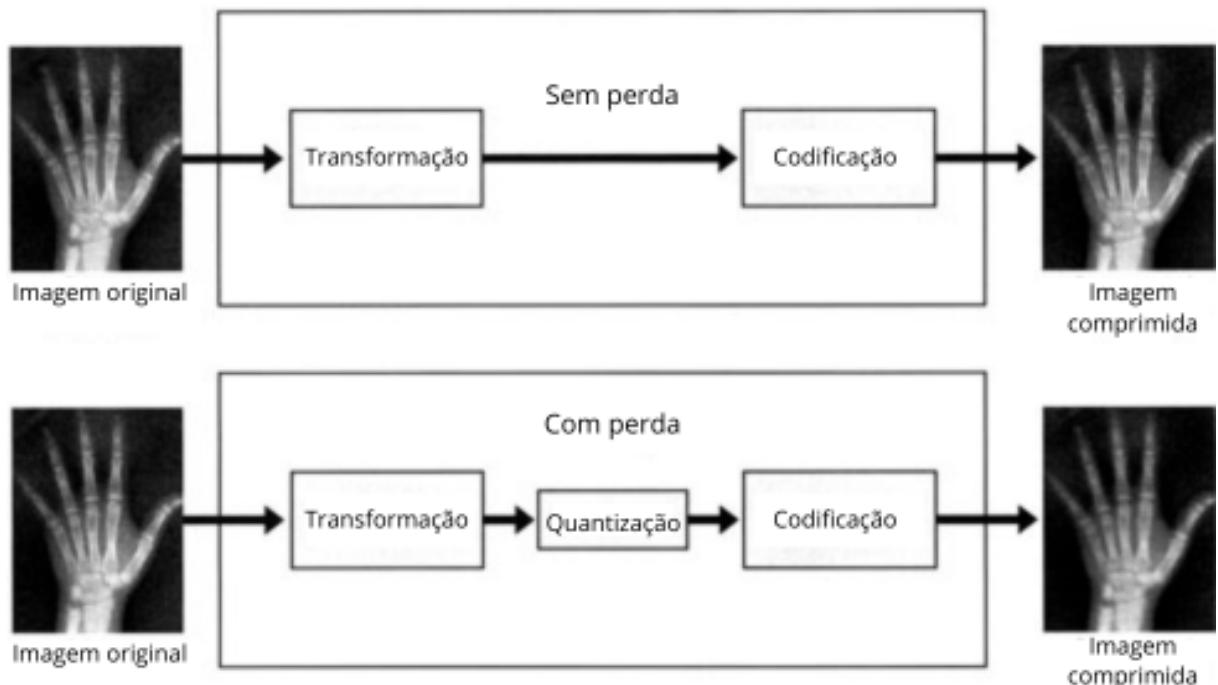
Fonte: (DIMILILER, 2022)

Quando falamos de compressão de dados, temos duas abordagens de algoritmos, os com perda e os sem perda, como ilustra a Figura 3.

2.1.2 Compressão sem perda

A compressão sem perda preserva totalmente a informação original, explorando apenas a redundância dos dados e garantindo que a descompressão resulte no arquivo idêntico ao original. O algoritmo de Huffman (HUFFMAN, 1952) é um exemplo clássico que utiliza códigos

Figura 3 – Comparação entre compressão com e sem perda



Fonte: Adaptada de (BIRADAR; MAKANDAR, 2022)

de comprimento variável para representar dados com diferentes frequências de ocorrência. Em outras palavras, em vez de atribuir um número fixo de bits para cada símbolo (como é o caso dos códigos de comprimento fixo), os códigos de comprimento variável permitem que símbolos mais comuns sejam representados por sequências de bits mais curtas, enquanto símbolos menos frequentes são representados por sequências de bits mais longas (ELAKKIYA; THIVYA, 2021). Isso resulta em uma representação mais eficiente dos dados, uma vez que os símbolos mais comuns são codificados com menos bits, enquanto ainda mantém a capacidade de recuperar integralmente as informações originais durante o processo de descompressão. Essa abordagem de compressão é preferível em cenários em que nenhuma perda de integridade do documento é aceitável, como aqueles que envolvem documentos legais ou arquivos executáveis.

2.1.3 Compressão com perda

A compressão com perda, por outro lado, sacrifica parte da informação para obter uma maior taxa de compressão. Essa técnica é frequentemente empregada quando uma perda mínima de qualidade é aceitável para reduzir significativamente o tamanho do arquivo. Um exemplo comum é a compressão JPEG. Ao contrário da compressão sem perda, que preserva integralmente as informações, a compressão com perda é mais flexível em relação à perda de informações. Ela é amplamente utilizada em cenários onde a qualidade ligeiramente inferior é

aceitável em troca de uma redução significativa no tamanho do arquivo. Isso inclui aplicações como *streaming* de vídeo, videoconferência e armazenamento de fotos em *smartphones*. Para medir a perda resultante dessa compressão, uma métrica comumente empregada é o *Mean Squared Error* (MSE), que quantifica a diferença entre os valores originais e os valores comprimidos (ELAKKIYA; THIVYA, 2021). A fórmula do MSE é dada por:

$$MSE = \frac{\sum_{i=1}^n (X_i - Y_i)^2}{n}$$

onde n representa o número total de símbolos ou dados a serem comprimidos. A expressão $\sum_{i=1}^n$ denota a soma dos termos, em que cada termo, $(X_i - Y_i)^2$, corresponde à diferença ao quadrado entre o valor original X_i e o valor reconstruído Y_i após a compressão. Essa operação garante que todas as diferenças sejam positivas e destaca as discrepâncias maiores entre os valores originais e os valores reconstruídos.

Além do MSE, outra métrica comum para avaliar a perda de informações durante a compressão é a *Peak Signal-to-Noise Ratio* (PSNR). A PSNR é frequentemente utilizada para medir a qualidade percebida da imagem após a compressão, fornecendo uma avaliação mais intuitiva para os usuários. A fórmula da PSNR é dada por:

$$PSNR = 10 \cdot \log_{10} \left(\frac{\text{Valor Máximo}^2}{MSE} \right)$$

Aqui, o Valor Máximo representa o intervalo dinâmico máximo dos dados, geralmente representado pelo valor máximo que pode ser representado na imagem. Uma PSNR mais alta indica uma menor perda de informações e uma qualidade visual mais preservada. Essas métricas, como MSE e PSNR, fornecem maneiras objetivas de quantificar a perda de qualidade durante a compressão de dados, sendo ferramentas essenciais na avaliação do desempenho de algoritmos de compressão com perda.

2.1.4 Entropia

No contexto de compressão de imagem, a entropia é uma medida estatística que se refere à incerteza ou aleatoriedade das informações contidas em uma imagem. Quanto maior a entropia, mais imprevisíveis são os dados e mais difícil é comprimi-los. A entropia é frequentemente utilizada para avaliar a eficiência da compressão sem perda, já que uma alta entropia implica em menor redundância nos dados, o que pode limitar a capacidade de compressão. A entropia de um conjunto de dados é calculada usando a teoria da informação de

Shannon (SAYOOD, 2006), onde essa é definida como a média ponderada das probabilidades dos símbolos no conjunto de dados. Matematicamente, a entropia de Shannon em bits $H(X)$ de uma variável aleatória discreta X com distribuição de probabilidade $P(X)$ é definida por:

$$H(X) = - \sum_{i=1}^n p(x_i) \log_2 p(x_i)$$

Onde $p(x_i)$ é a probabilidade do símbolo (x_i) ocorrer no conjunto de dados.

Em imagens, a entropia é uma medida de quantidade de informação contida na imagem. Imagens com alta entropia tem uma maior variedade de cores e textura, o que torna mais difícil encontrar padrões repetidos e redundâncias que podem ser explorados para compressão, enquanto que imagens com baixa entropia têm menos variação e podem ser mais facilmente comprimidas.

2.1.5 *Discrete Cosine Transformation (DCT)*

A *Discrete Cosine Transformation* (DCT) é uma técnica essencial na compressão de imagens, particularmente em algoritmos como o JPEG. Ela desempenha um papel crucial ao converter os dados espaciais, ou seja, as informações sobre a intensidade luminosa de cada pixel e sua localização na imagem em dados de frequência. Essa transformação é realizada por meio de uma série de operações matemáticas que convertem a informação de pixel em componentes de frequência (GONZALEZ; WOODS, 2008).

A DCT divide a imagem em pequenos blocos e é aplicada a cada bloco separadamente. Durante esse processo, os padrões de variação são analisados na intensidade dos pixels dentro de cada bloco e são expressos em termos de frequência. Isso significa que a transformada identifica quais frequências estão presentes na imagem e em que intensidade, onde coeficientes de frequência de alta amplitude representam componentes de imagem que contribuem significativamente para a aparência visual, enquanto coeficientes de baixa amplitude representam detalhes menos perceptíveis. A definição da DCT é dada por:

$$F(u, v) = \frac{1}{\sqrt{2N}} C(u) C(v) \sum_{x=0}^{N-1} \sum_{y=0}^{N-1} f(x, y) \cos \left[\frac{(2x+1)u\pi}{2N} \right] \cos \left[\frac{(2y+1)v\pi}{2N} \right]$$

onde $F(u, v)$ é o coeficiente da transformada na posição (u, v) , $f(x, y)$ é o valor do pixel na posição (x, y) , N é o tamanho da imagem $C(u)$ e $C(v)$ são coeficientes de normalização. A expressão matemática da DCT descreve como a transformação é realizada mapeando os valores de intensidade dos pixels para coeficientes de frequência, concentrando a energia da imagem

nos coeficientes de frequência mais significativos e descartando ou reduzindo os coeficientes de frequência de baixa amplitude

2.1.6 Quantização

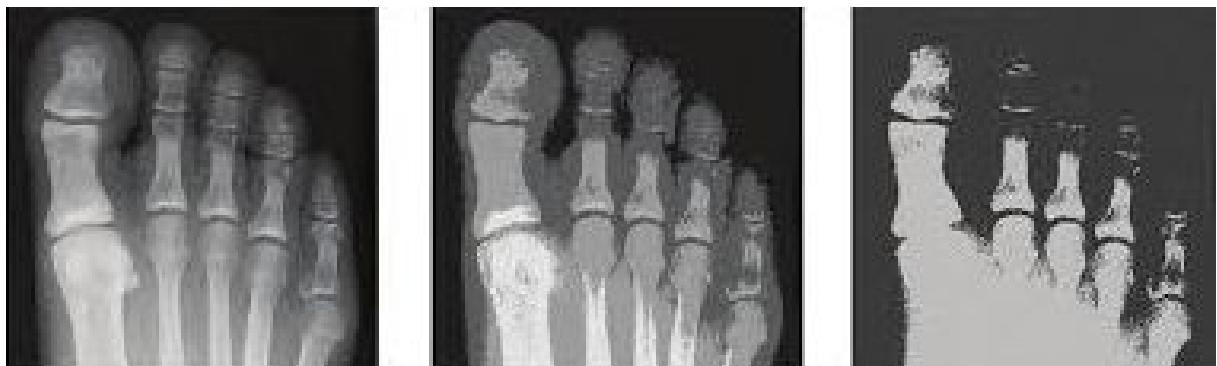
A quantização é uma etapa essencial da compressão de imagem, que depende diretamente da DCT. Após a aplicação da DCT, os coeficientes de frequência resultantes são quantizados para reduzir a quantidade de dados necessários para representar a imagem. Esta etapa é crítica, pois determina o nível de perda de qualidade que ocorrerá na imagem comprimida. A quantização é realizada dividindo-se os coeficientes de frequência pelos valores correspondentes na matriz de quantização e arredondando os resultados para o valor mais próximo. Isso resulta na perda de informações menos importantes da imagem, o que leva a uma redução significativa no tamanho da imagem.

A matriz de quantização controla o nível de compressão e, consequentemente, a taxa de perda de qualidade. Ao ajustar os valores na matriz de quantização, é possível parametrizar a compressão para comprimir mais ou menos. Reduzir os valores na matriz de quantização resulta em uma compressão mais agressiva, o que leva a uma maior perda de qualidade na imagem comprimida. Por outro lado, aumentar os valores na matriz de quantização produz uma compressão menos agressiva, preservando mais detalhes na imagem. A quantização é definida por:

$$F_q(u, v) = \text{round} \left(\frac{F(u, v)}{Q(u, v)} \right)$$

Onde $F_q(u, v)$ é o coeficiente de frequência quantizado, $F(u, v)$ é o coeficiente de frequência original obtido pela DCT, e $Q(u, v)$ é o valor correspondente na matriz de quantização. Essa equação exemplifica como a quantização é realizada, ajustando os coeficientes de frequência para reduzir a quantidade necessária de dados para representar a imagem. A Figura 4 compara três diferentes níveis de quantização, demonstrando como o aumento da quantização, ou seja, a diminuição de dados necessários para representar a imagem, afeta a nitidez, os detalhes e a fidelidade visual da imagem comprimida.

Figura 4 – Comparação entre diferentes níveis de quantização



Fonte: Adaptada de (LI *et al.*, 2020)

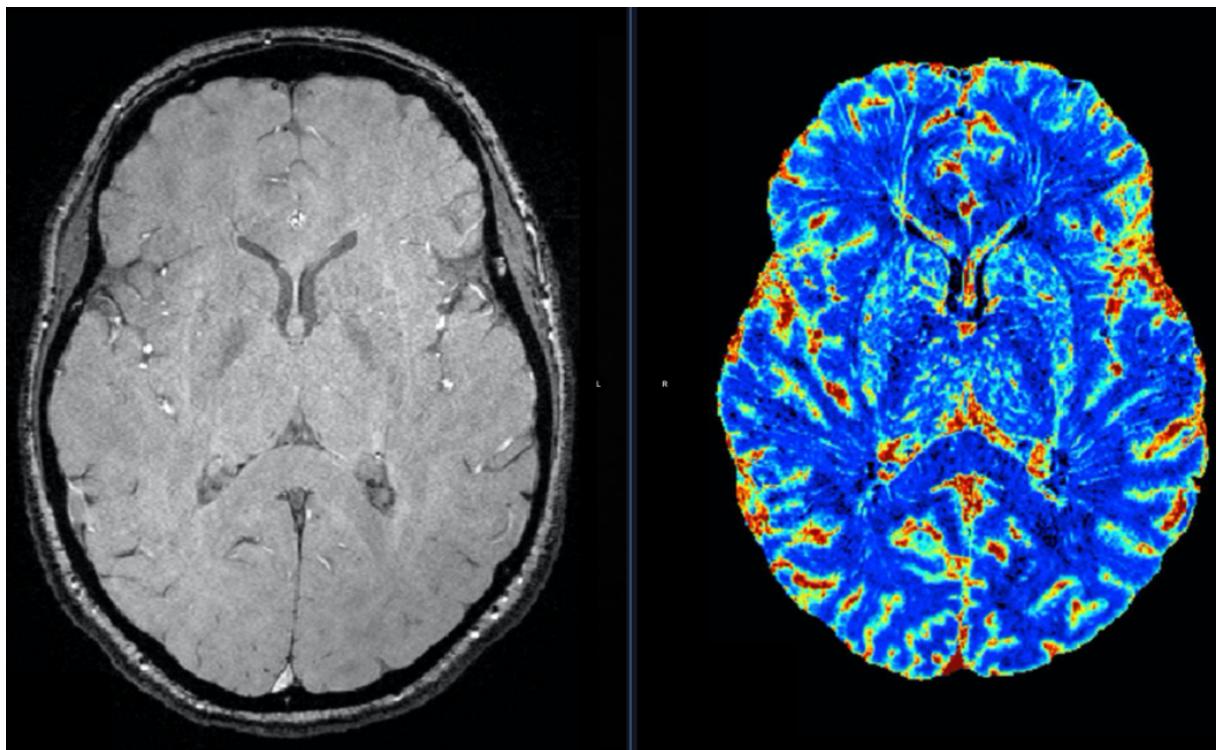
2.1.7 *Red, Green, Blue (RGB) vs Escala de cinza (Grayscale)*

Imagens em *Red, Green, Blue (RGB)* são compostas por três canais de cores: vermelho, verde e azul. Cada pixel na imagem é representado por uma combinação desses três canais, onde a intensidade de cada canal determina a cor específica desse pixel. Geralmente, cada canal é representado por 8 bits, o que significa que cada canal pode ter 256 valores diferentes de intensidade, variando de 0 a 255. Portanto, uma imagem RGB típica possui 24 bits, ou 3 bytes, por pixel (8 bits para cada canal), resultando em uma gama de cores muito ampla e uma representação rica da imagem (GONZALEZ; WOODS, 2008).

Por outro lado, as imagens em escala de cinza são compostas por apenas um canal de intensidade luminosa, onde a cor de cada pixel é representada por um único valor de intensidade. Cada pixel em uma imagem em escala de cinza é representado por um valor de 8 bits, variando de 0 a 255, onde 0 representa preto e 255 representa branco (GONZALEZ; WOODS, 2008). Essa representação simplificada é adequada para imagens médicas, como as tomografias, onde a ênfase está na intensidade do sinal em vez das cores.

As imagens em escala de cinza requerem menos espaço de armazenamento e processamento computacional em comparação com as imagens RGB, o que é vantajoso ao lidar com grandes conjuntos de dados de tomografia. Portanto, ao analisar imagens de tomografia, é comum utilizar imagens em escala de cinza para representar com precisão as informações médicas relevantes.

Figura 5 – Visualização de uma imagem em escala de cinza e RGB



Fonte: Extraída de (VEIKUTIS *et al.*, 2023)

2.2 *Digital Imaging and Communications in Medicine (DICOM)*

O DICOM é um padrão internacional fundamental para o armazenamento, transmissão e troca de informação de imagens médicas digitais (NEMA, 2016). Além de fornecer um formato padronizado, o DICOM também estabelece diretrizes para metadados associados, como informações de paciente, estudo, série e imagem, como ilustrado na Figura 6. Uma característica distintiva das imagens DICOM é a inclusão desses metadados detalhados, que permitem uma melhor compreensão e interpretação das imagens no contexto clínico.

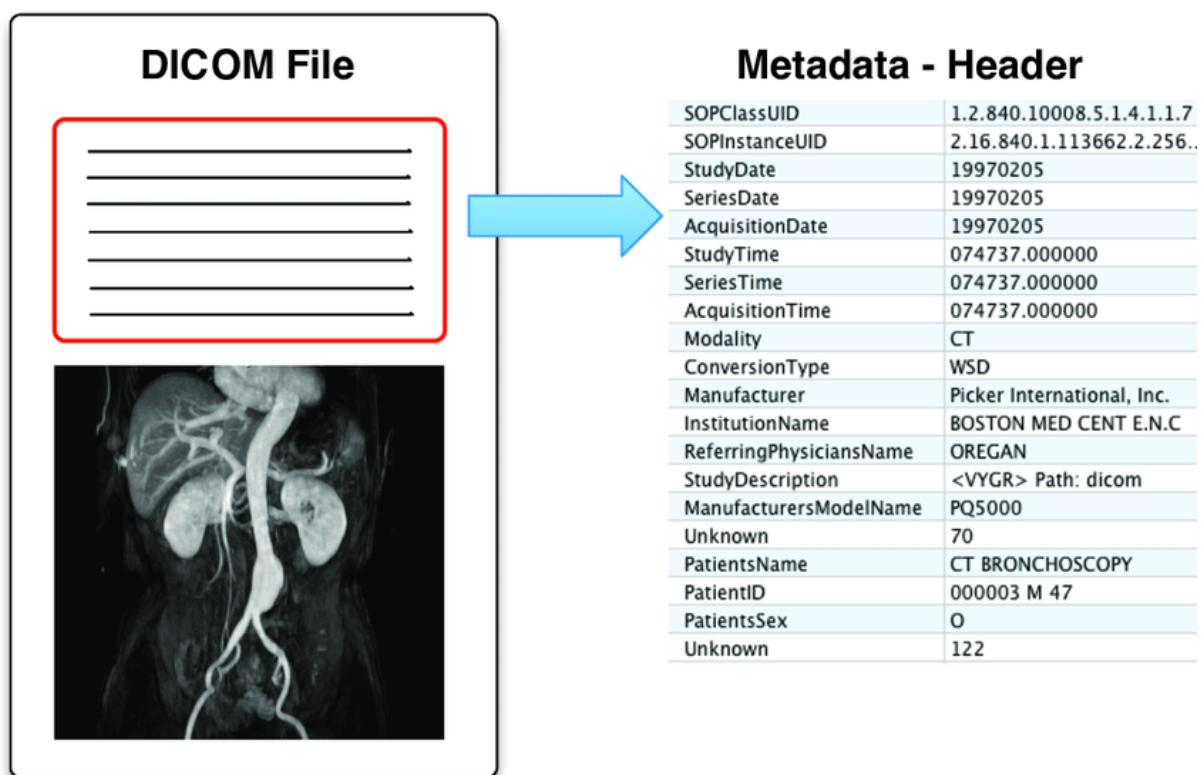
Uma imagem é considerada DICOM quando segue as especificações do padrão DICOM, incluindo a estrutura de metadados e os requisitos de formato de arquivo. Essas imagens podem ser adquiridas por uma variedade de dispositivos médicos, como tomógrafos, ressonâncias magnéticas e sistemas de ultrassom, e são comumente usadas em diagnósticos por imagem, planejamento de tratamento e monitoramento de pacientes.

Quanto à compressão, as imagens DICOM podem ser armazenadas em formato comprimido ou não comprimido, e essa informação é incluída nos metadados da imagem através do atributo *TransferSyntaxUID*, onde este indica o esquema de codificação ou compressão de dados aplicado a uma imagem ou conjunto de dados DICOM, e a ausência desse campo indica

que a imagem não está comprimida (NEMA, 2016).

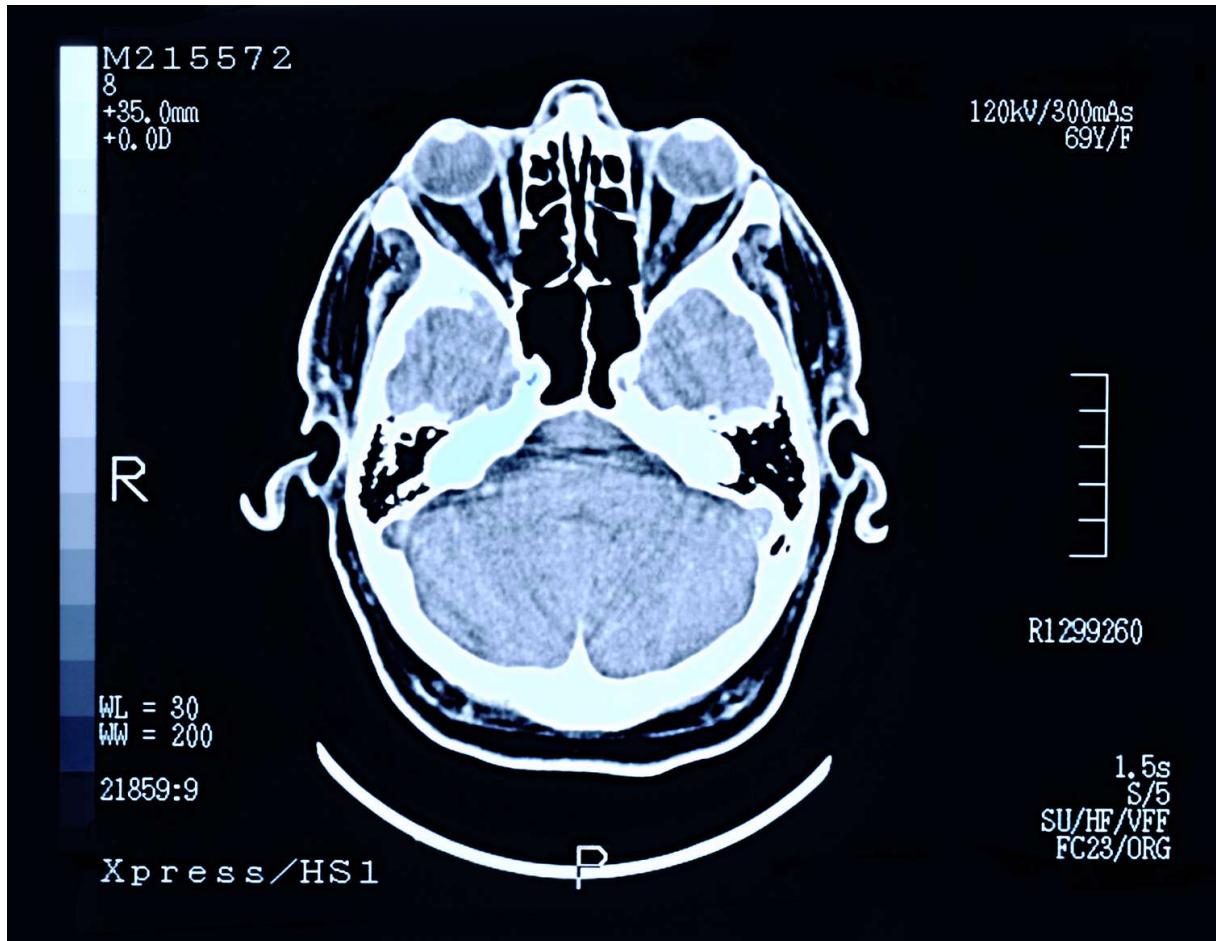
Embora seja amplamente adotado, ele tende a gerar arquivos volumosos devido aos metadados detalhados. Isso representa um desafio para o armazenamento eficiente, especialmente em ambientes hospitalares. A compressão de imagens DICOM é uma solução, mas pode impactar na qualidade diagnóstica, especialmente com compressão com perda. É essencial encontrar um equilíbrio entre a redução do tamanho dos arquivos e a preservação da qualidade das imagens para garantir diagnósticos precisos e tratamentos eficazes na prática clínica. A Figura 7 ilustra a visualização de uma imagem DICOM.

Figura 6 – Metadados de uma imagem DICOM



Fonte: Extraída de (SILVA; COSTA, 2011)

Figura 7 – Visualização de uma imagem DICOM



Fonte: Extraída de (STINY, 2015)

2.3 ALGORITMO DE HUFFMAN

O algoritmo de Huffman (HUFFMAN, 1952) é um método de compressão sem perda que utiliza codificação de comprimento variável para representar símbolos de entrada com base em suas frequências de ocorrência. Desenvolvido em 1952 por David A. Huffman, esse algoritmo tem sido amplamente utilizado em uma variedade de aplicações de compressão de dados.

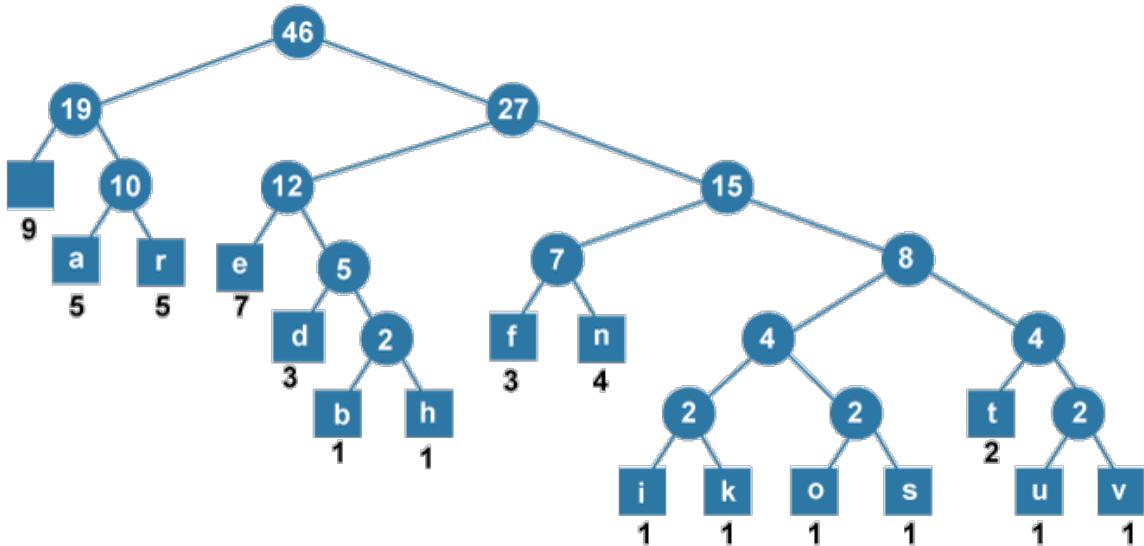
Para fins de ilustração, na Figura 8, podemos ver que o símbolo “a” possui 5 ocorrências, enquanto o símbolo “v” possui apenas uma, então o caminho (quantidade de bits) para se representar o “a” é menor do que para se representar o “v”.

O processo de compressão consiste nas seguintes etapas:

1. Leitura dos dados de entrada:

Todo o conteúdo do arquivo é lido do disco e armazenado na memória para manipulação

Figura 8 – Árvore de Huffman para uma sequência de caracteres aleatórios



Fonte: (JAVATPOINT, 2021)

posterior. Este passo é estratégico para o desempenho do algoritmo, pois permite que os dados sejam processados de forma eficiente. Uma abordagem alternativa seria processar os dados diretamente no arquivo, mas isso poderia resultar em perda de desempenho, especialmente para arquivos muito grandes.

2. Construção da Fila de Prioridade:

Nesta etapa do algoritmo de Huffman, os dados são utilizados para criar uma fila de prioridade com base na frequência de ocorrência dos símbolos presentes no texto original. Essa fila de prioridade é uma estrutura de dados que organiza os elementos de acordo com sua relevância, garantindo que os símbolos mais frequentes, que tendem a ter códigos mais curtos, sejam processados primeiro durante a construção da árvore de Huffman. Cada vez que um novo símbolo é encontrado no texto original, um nó é criado na fila de prioridade. Se o símbolo já está presente na fila, sua frequência é incrementada e o nó correspondente é reordenado na lista.

3. Construção da Árvore Trie:

A partir da fila de prioridade construída anteriormente, os dois nós de menor frequência (os dois primeiros) são removidos da fila e combinados para formar um novo nó que é reinserido na fila. Esse processo é repetido até que apenas um nó permaneça na fila, representando a raiz da árvore de Huffman. Esta árvore é ilustrada na Figura 8.

4. Construção da Tabela de Códigos:

Uma vez construída a árvore de Huffman, uma tabela de códigos é criada para mapear cada símbolo ao seu código binário correspondente. Isso é feito percorrendo a árvore recursivamente, atribuindo códigos binários aos símbolos folha (FEOFILOFF, 2018). Os símbolos mais frequentes recebem códigos mais curtos, enquanto os menos frequentes recebem códigos mais longos.

5. Transformação do texto original em cadeia de bits:

Utilizando a tabela de códigos, o texto original é transformado em uma cadeia de bits substituindo cada símbolo pelo seu código correspondente. Isso resulta em uma representação compacta do texto original, composta apenas por zeros e uns.

6. Construção do fluxo de bytes comprimidos:

A cadeia de bits gerada na etapa anterior é convertida em um fluxo de bytes comprimido, necessário porque os dados são armazenados em arquivos binários, e não diretamente como bits individuais.

Uma das principais vantagens do algoritmo de Huffman (HUFFMAN, 1952) é a sua capacidade de produzir uma representação compacta dos dados, especialmente para conjuntos de dados com distribuições de frequência desiguais. No entanto, a eficiência do algoritmo depende da capacidade de prever as frequências de ocorrência dos símbolos de entrada com precisão. Em alguns casos, a construção da árvore de Huffman pode ser computacionalmente intensiva, especialmente para conjuntos de dados grandes (HUFFMAN, 1952).

A complexidade de espaço do algoritmo de Huffman é dominada pelo tamanho da árvore de Huffman e pela tabela de códigos resultante, aproximadamente $O(n)$ para uma árvore ótima, onde n é o número de símbolos distintos na entrada. Em termos de tempo, a construção da árvore de Huffman é $O(n \log n)$ devido à combinação na fila de prioridade, enquanto a compressão dos dados é $O(m)$, com m sendo o número total de bits no texto original. Essas características tornam o algoritmo de Huffman eficiente para compressão de dados em várias aplicações.

Algoritmo 1: Codificação de Huffman

Input: Conjunto de caracteres e suas frequências**Output:** Tabela de códigos de Huffman

Iniciarizar uma fila de prioridade Q com os nós folha para cada caractere com sua

frequência; **while** $|Q| > 1$ **do**

$x \leftarrow$ extrair o nó de menor frequência de Q ; $y \leftarrow$ extrair o próximo nó de menor

frequência de Q ; Criar um novo nó z como nó interno com frequência

$freq(z) = freq(x) + freq(y)$; $z.esquerda \leftarrow x$; $z.direita \leftarrow y$; Inserir z de volta em

Q ;

end

Árvore de Huffman resultante é a única raiz restante em Q ; Derivar os códigos de

Huffman percorrendo a árvore a partir da raiz;

2.4 ALGORITMOS DE COMPRESSÃO DE IMAGENS

2.4.1 Portable Network Graphics (PNG)

PNG é um formato de arquivo de imagem amplamente difundido que utiliza compressão sem perda de dados. A compressão PNG é baseada no algoritmo DEFLATE (SAYOOD, 2006), que é uma combinação de dois outros algoritmos: Lempel-Ziv 1977 (LZ77) (ZIV; LEMPEL, 1977) e Huffman (HUFFMAN, 1952). O processo de compressão de uma imagem para o formato PNG consiste nas seguintes etapas:

1. Pré-processamento:

Antes da compressão, a imagem passa por um pré-processamento que pode incluir técnicas como o *filtering prediction* (ELAKKIYA; THIVYA, 2021). O *filtering prediction* aplica filtros preditivos aos dados de imagem para estimar os valores dos pixels com base nos valores dos pixels vizinhos, ou seja, aqueles que estão na mesma linha ou coluna (ELAKKIYA; THIVYA, 2021). Existem cinco tipos de filtros preditivos utilizados no formato PNG:

- Nenhum: Sem filtragem, os valores dos pixels são usados diretamente.
- Sub: O valor do pixel atual menos o valor do pixel anterior na linha.
- Up: O valor do pixel atual menos o valor do pixel acima na coluna.
- Average: A média dos pixels anterior na linha e acima na coluna subtraída do valor do pixel atual.

- Paeth: Um algoritmo que usa uma função preditiva para escolher o pixel mais próximo entre os pixels anterior, acima e a soma dos dois menos o pixel na diagonal superior esquerda.

O filtro de predição por subtração, por exemplo, pode ser representado pela seguinte fórmula:

$$Pixel_{\text{predito}} = Pixel_{\text{atual}} - Pixel_{\text{vizinho}}$$

Ao aplicar esses filtros, a redundância nos dados de imagem é reduzida, o que aumenta a eficiência do algoritmo de compressão DEFLATE. Isso resulta em arquivos PNG mais compactos e mais eficientes para armazenamento.

2. Compressão com DEFLATE:

O DEFLATE opera em duas principais etapas: a compactação com LZ77 e codificação de Huffman

- Compactação: O algoritmo LZ77 (ZIV; LEMPEL, 1977) procura por padrões repetidos de dados dentro de bloco. Ele substitui esses padrões por referências a cópias anteriores dos mesmos dados, seguido pela distância e pelo comprimento dessas cópias. Isso reduz a redundância nos dados e permite uma representação mais compacta.
- Codificação: Após a compactação, os dados da imagem são codificados usando o algoritmo de codificação de Huffman (HUFFMAN, 1952). Este atribui códigos mais curtos para padrões de pixels comuns, enquanto símbolos menos comuns, como detalhes finos ou ruído de imagem, recebem códigos mais longos, resultando em uma representação mais eficiente, onde a informação visual é preservada de forma otimizada.

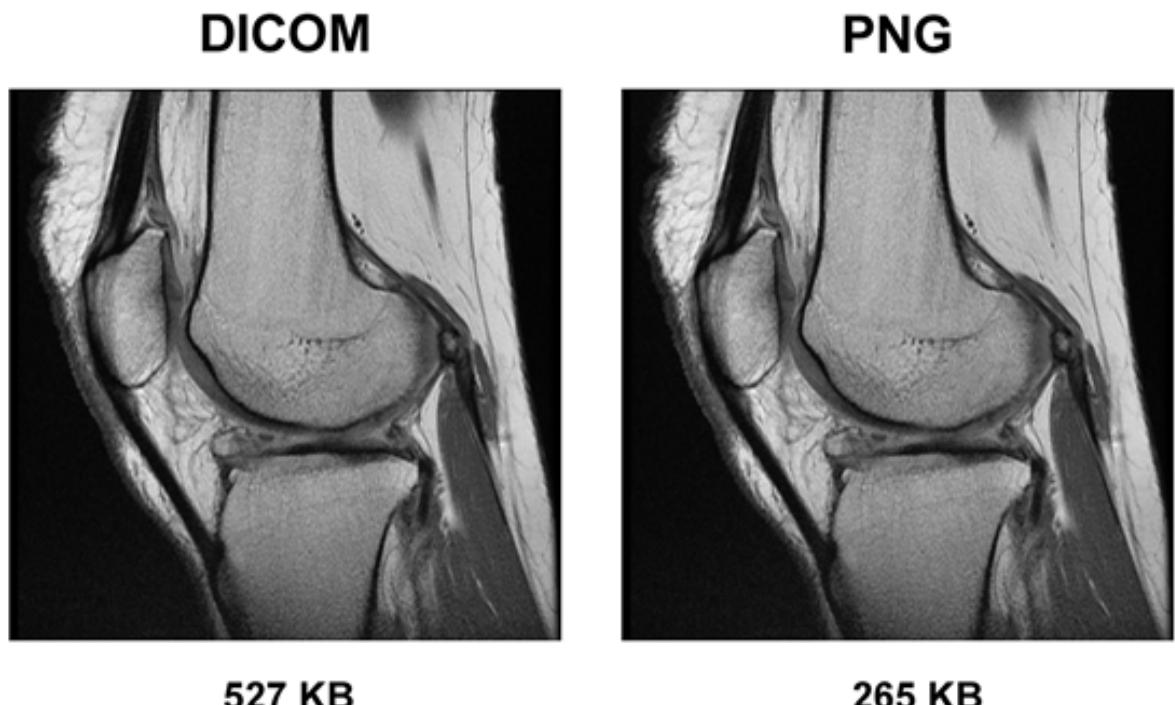
3. Estruturação em Chunks:

A imagem PNG é organizada em pedaços chamados "chunks". Cada chunk contém uma parte específica dos dados da imagem ou metadados. Os principais chunks incluem:

- IHDR: Contém informações básicas da imagem, como largura, altura, profundidade de cor e tipo de cor.
- IDAT: Contém os dados da imagem comprimidos.
- PLTE: Contém a paleta de cores, se aplicável.
- IEND: Indica o fim da imagem.

As etapas de compressão do PNG, como o pré-processamento, compressão com DEFLATE, e estruturação em chunks, são essenciais para reduzir o tamanho dos arquivos de imagem mantendo sua qualidade. *filtering prediction* reduz a redundância, enquanto o DEFLATE proporciona uma compressão eficiente (GONZALEZ; WOODS, 2008). Essas etapas garantem arquivos compactos sem comprometer a qualidade da imagem.

Figura 9 – Compressão de imagem com PNG



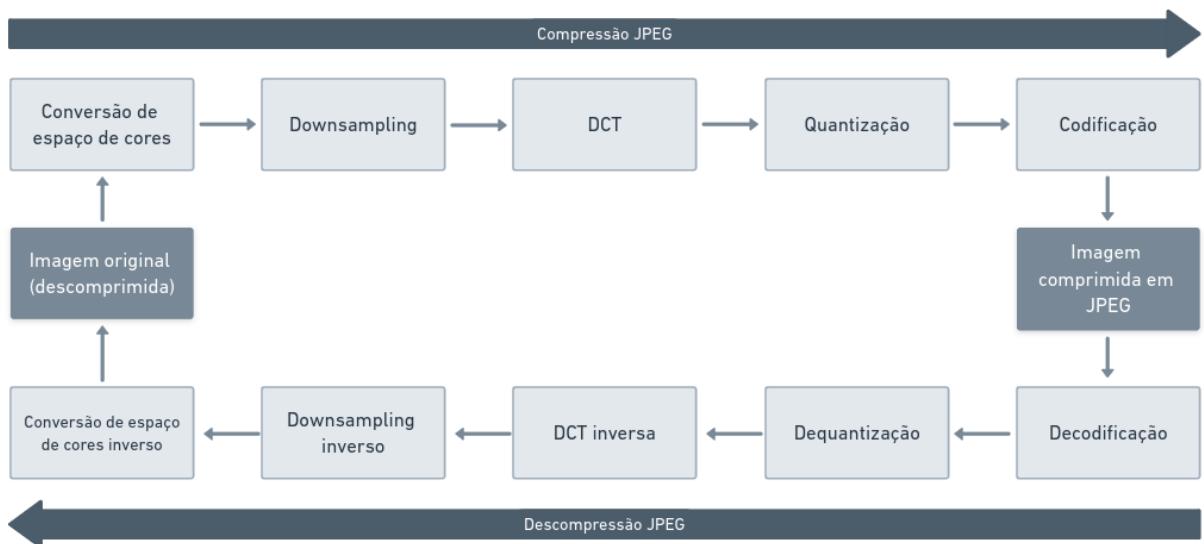
Fonte: (ANON, 2024)

Considerando o desempenho da compressão PNG, é crucial analisar tanto a complexidade de espaço quanto de tempo envolvida nesse processo. Em termos de complexidade de espaço, a quantidade de memória necessária para armazenar os dados intermediários durante a compressão e descompressão impacta diretamente no desempenho. Isso inclui a memória utilizada para manter as estruturas de dados para a fila de prioridade e a árvore de Huffman (HUFFMAN, 1952), bem como os *buffers* para armazenar os dados comprimidos e descomprimidos. Além disso, a complexidade de tempo é influenciada pelo tamanho em bytes da imagem, uma vez que a aplicação dos algoritmos é realizada para a imagem inteira. Quanto maior o tamanho da imagem, mais tempo será necessário para processá-la. Todos esses fatores combinados podem impactar a complexidade de tempo e espaço da compressão PNG. (GONZALEZ; WOODS, 2008)

2.4.2 Joint Photographic Experts Group (JPEG)

JPEG é um formato de compressão de imagens com perdas amplamente utilizado que emprega uma combinação de técnicas para reduzir o tamanho do arquivo, sem perder muita qualidade visual (MIANO, 1999). Para imagens coloridas, o processo de compressão JPEG envolve várias etapas fundamentais, incluindo a conversão de espaço de cores e *downsampling*. No entanto, para imagens em escala de cinza, como elas possuem apenas um canal de cor (luminância) e não têm componentes de crominância, essas duas etapas não são necessárias (GONZALEZ; WOODS, 2008). Portanto, o processo de compressão JPEG para imagens em escala de cinza é simplificado em comparação com imagens coloridas. A Figura 10 ilustra o processo de compressão e descompressão desse formato, as etapas principais incluem:

Figura 10 – Fluxo de compressão e descompressão do JPEG



Fonte: Elaborado pelo autor

1. Conversão de Espaço de Cores (*Color Space Conversion*): Antes da compressão, a imagem é convertida de seu espaço de cores original para outro espaço de cores mais adequado. Isso é especialmente importante para imagens em escala de cinza, onde a conversão para um espaço de cores como o YCbCr pode melhorar a eficiência da compressão. No caso das imagens em escala de cinza, embora tenham apenas um canal de cor (luminância), a conversão para o espaço de cores YCbCr ainda pode ser benéfica. Isso ocorre porque a representação YCbCr separa a informação de luminância (Y) das informações de crominância (Cb e Cr), permitindo que a compressão se concentre principalmente na luminância, que é mais perceptível aos olhos humanos (MIANO, 1999).

2. *Downsampling*: A etapa de *downsampling* é usada para reduzir a resolução das componentes de crominância (Cb e Cr) mantendo a resolução da luminância (Y). Isso é feito porque as informações de cor nas imagens podem ser redundantes, especialmente nas componentes de crominância. No entanto, para imagens em escala de cinza, essa etapa é ignorada, pois não há informações de crominância para serem amostradas (MIANO, 1999).
3. DCT: Após a conversão do espaço de cores e o *downsampling*, cada bloco da imagem é submetido à transformada discreta do cosseno DCT. Essa converte os dados espaciais da imagem em coeficientes de frequência, separando os componentes de alta e baixa frequência. Isso permite uma representação mais eficiente da imagem, concentrando a energia nos coeficientes de frequência mais significativos (MIANO, 1999).
4. Quantização: Os coeficientes de frequência resultantes da DCT são quantizados para reduzir a quantidade de dados necessários para representar a imagem. Esta etapa introduz perda de qualidade, pois envolve a redução da precisão dos coeficientes de frequência menos significativos. A matriz de quantização é ajustada para controlar o nível de compressão e, consequentemente, a taxa de perda de qualidade (MIANO, 1999).
5. *Run-Length Encoding* e *Huffman Coding*: Após a quantização, os coeficientes de frequência quantizados são submetidos à codificação de *Run Length* (RLE) e, em seguida, à codificação de Huffman (HUFFMAN, 1952). A codificação RLE é utilizada para comprimir sequências de zeros consecutivos nos dados quantizados, enquanto a codificação de Huffman (HUFFMAN, 1952) atribui códigos de comprimento variável aos símbolos com base em sua probabilidade de ocorrência. Essas técnicas de codificação contribuem para uma compressão eficiente dos dados, reduzindo ainda mais o tamanho da imagem (MIANO, 1999).

Essas etapas juntas compõem o processo de compressão JPEG, que possibilita a redução do tamanho do arquivo de imagem com perdas controladas. Embora a qualidade da imagem seja comprometida devido à perda de informações durante a quantização, o algoritmo JPEG oferece um equilíbrio adequado entre tamanho do arquivo e qualidade visual aceitável para uma ampla gama de aplicações (GONZALEZ; WOODS, 2008).

Considerando o desempenho da compressão JPEG, é crucial analisar tanto a complexidade de espaço quanto de tempo envolvida nesse processo. Em termos de complexidade de espaço, a quantidade de memória necessária para armazenar os dados intermediários durante a compressão e descompressão impacta diretamente no desempenho. Isso inclui a memória utili-

zada para manter os blocos de pixels, as estruturas de dados para a fila de prioridade e as tabelas de Huffman, bem como os buffers para armazenar os dados comprimidos e descomprimidos. Além disso, a complexidade de tempo é influenciada pelo tamanho em bytes da imagem, uma vez que a compactação é realizada para cada bloco individualmente. Quanto maior o tamanho da imagem, mais blocos serão processados, aumentando assim a complexidade de tempo da compressão e descompressão JPEG. Todos esses fatores combinados podem impactar a eficiência e o desempenho geral da compressão JPEG.

2.4.3 Principal Component Analysis (PCA)

Principal Component Analysis (PCA) é uma técnica fundamental em análise de dados e aprendizado de máquina amplamente utilizada para redução de dimensionalidade de dados (DILLON; GOLDSTEIN, 1984). O PCA é uma abordagem estatística que busca encontrar as direções de maior variabilidade nos dados, representadas pelos autovetores da matriz de covariância, e projetar os dados nesses componentes principais. Essa técnica tem aplicações em diversas áreas, incluindo reconhecimento de padrões, visão computacional e compressão de dados. As etapas principais dessa abordagem para compressão de imagens são:

1. Preparação da imagem: A imagem é convertida para escala de cinza, reduzindo a quantidade de canais da imagem, mantendo apenas o canal de nível de cinza, sendo cada pixel representado por um valor entre 0 e 255, onde 0 é preto, e 255, branco (DILLON; GOLDSTEIN, 1984).
2. Organização dos dados: A matriz de pixels é convertida em um vetor unidimensional de tamanho $m \times n$, onde m representa a quantidade de linhas e n a quantidade de colunas da matriz, ou seja, se a imagem tiver uma resolução de 512x512 o resultado seria um vetor unidimensional de tamanho 262.144 (512x512), onde cada elemento do vetor representa a intensidade do pixel em uma posição específica da imagem (DILLON; GOLDSTEIN, 1984).
3. Centralização dos dados: Após a organização dos dados, é calculada a média de todos os valores de intensidade dos pixels na imagem. O valor dessa média é subtraído de cada valor de pixel no vetor de dados. Isso centraliza os dados em torno de zero, removendo a informação de brilho médio da imagem (DILLON; GOLDSTEIN, 1984).
4. Cálculo da matriz de covariância: A partir da centralização dos dados, é calculada a matriz de covariância. Covariância entre dois pixels indica como eles variam juntos,

uma covariância positiva entre os pixels sugere que eles variam juntos na mesma direção, enquanto uma covariância negativa indica que eles variam em direções opostas. Isso ajuda a identificar as direções principais de variabilidade nos dados, que são representadas pelos autovetores da matriz de covariância. Essas direções principais são usadas para comprimir e reconstruir a imagem com perda mínima de informação (DILLON; GOLDSTEIN, 1984).

5. Decomposição da matriz de covariância: Decompondo a matriz de covariância são obtidos os autovetores e autovalores. Onde os autovetores representam as direções principais de variabilidade nos dados, enquanto os autovalores indicam a quantidade de variância ao longo de cada uma dessas direções (DILLON; GOLDSTEIN, 1984).
6. Seleção dos componentes principais: Após a decomposição da matriz de covariância, os autovetores são ordenados de acordo com seus autovalores correspondentes, em ordem decrescente. Dessa forma, os autovetores com os maiores autovalores contêm a maior parte da variância dos dados e, portanto, são tratados como os componentes principais (DILLON; GOLDSTEIN, 1984).
7. Compressão: Nesta etapa, o algoritmo se torna parametrizável, permitindo que escolhamos a quantidade de componentes principais para representar a imagem. Em outras palavras, quanto menos componentes principais forem selecionados, maior será a taxa de compressão e menor será a qualidade da imagem resultante. Ao escolher a quantidade de componentes principais, é multiplicado o vetor de dados centralizados pelos autovetores correspondentes aos n maiores autovalores, onde n é o número de componentes selecionados, e então é adicionado a média de volta ao vetor resultante. Isso constrói uma versão comprimida da imagem original em formato de vetor, mantendo apenas as informações mais relevantes em termos de variabilidade de dados (DILLON; GOLDSTEIN, 1984).
8. Descompressão: Para reconstruir a imagem original, é multiplicada o vetor comprimido da imagem original pelos autovetores transpostos (ou seja, os autovetores originais), e então adicionada a média de volta para obter a imagem reconstruída (DILLON; GOLDSTEIN, 1984).

3 TRABALHOS RELACIONADOS

Neste capítulo, apresentamos uma revisão dos trabalhos relacionados ao tema do nosso estudo. O objetivo é fornecer uma visão geral dos estudos anteriores que abordam questões semelhantes às que estamos investigando. Ao revisar esses trabalhos, buscamos identificar lacunas no conhecimento existente e destacar como nossa pesquisa contribui para preencher essas lacunas.

3.1 PROCESSOS DE COMPRESSÃO DE DADOS APLICADOS A IMAGENS MÉDICAS

No estudo (STOLFI; CAMPOS, 2000), o autor aborda a aplicação de técnicas de compressão de dados em imagens médicas, com foco específico na cineangiografia, uma técnica de imagem que registra o fluxo sanguíneo dentro dos vasos. Ele ressalta a importância da qualidade e fidelidade na reprodução das imagens médicas para diagnósticos precisos e procedimentos médicos. Reconhecendo a necessidade de altas taxas de compressão sem perdas, o autor destaca os desafios associados especialmente em imagens ruidosas.

Para abordar esses desafios, propõe-se a implementação de um sistema de compressão de imagem em movimento, com ênfase na cineangiografia. O autor desenvolve um processo de compensação de movimento baseado em semelhança de forma para otimizar a extração de vetores em movimento, visando melhorar tanto a taxa de compressão quanto a qualidade da imagem reconstruída em comparação com métodos tradicionais. Além disso, explora-se o uso de quantização não linear e pós-processamento das imagens reconstruídas para reduzir a visibilidade de erros introduzidos durante o processo de compressão. Destaca-se a importância da avaliação dos resultados por meio de um ambiente de visualização de imagens, permitindo comparações entre diferentes métodos de processamento.

Em resumo, o trabalho representa uma contribuição significativa para a área de compressão de dados em imagens médicas, uma vez que explora essas compressões para o contexto específico da cineangiografia.

3.2 COMPRESSÃO DE IMAGENS MAMOGRÁFICAS UTILIZANDO SEGMENTAÇÃO E O ALGORITMO PPM

A principal problemática abordada no artigo (MARQUES *et al.*, 2007) é a necessidade de comprimir imagens mamográficas de forma eficiente, preservando informações

essenciais para diagnósticos precisos. A digitalização de imagens mamográficas resulta em arquivos de grande tamanho, o que pode sobrecarregar os sistemas de armazenamento e dificultar a transmissão dessas imagens, impactando a eficiência dos processos médicos. Para solucionar essa questão, os autores propuseram um método que combina a segmentação por limiarização, a decomposição da imagem em planos de bits e a utilização do algoritmo de compressão *Prediction by Partial Matching* (PPM). Essa abordagem permitiu alcançar taxas de compressão competitivas em relação a outros compressores avançados, ao mesmo tempo em que preservou a qualidade e a integridade das informações contidas na imagem original.

Em resumo, o estudo destaca a relevância da inovação tecnológica na área de compressão de imagens médicas, demonstrando que a combinação dessas técnicas pode resultar em benefícios significativos para a área da saúde. Essa abordagem não apenas contribui para a otimização do armazenamento e transmissão de imagens mamográficas, mas também pode facilitar a análise e o compartilhamento desses dados, auxiliando profissionais de saúde em diagnósticos mais precisos e eficazes.

3.3 UTILIZAÇÃO DA ANÁLISE DE COMPONENTES PRINCIPAIS NA COMPRESSÃO DE IMAGENS DIGITAIS

A problemática abordada em (SANTO, 2012) estava relacionada à necessidade de comprimir imagens médicas de forma eficiente, mantendo as informações essenciais para o diagnóstico clínico, ao mesmo tempo em que se reduz o espaço de armazenamento necessário. A compressão de imagens é crucial em ambientes médicos, onde grandes volumes de dados de imagem são gerados diariamente e o armazenamento eficiente é fundamental para a gestão e análise dessas informações. O autor explorou o PCA como uma ferramenta estatística para redução da dimensionalidade dos dados de imagem. A aplicação do PCA permitiu representar as imagens em uma estrutura computacional de dimensão reduzida, preservando as características principais da imagem original. Isso foi alcançado por meio da projeção dos dados em um subespaço gerado por um sistema de eixos ortogonais, obtido através do método *Singular Values Decomposition* (SVD) (SANTO, 2012).

Os resultados do estudo demonstraram que as imagens médicas comprimidas mantiveram suas principais características até aproximadamente 1/4 do tamanho original, ou seja, uma taxa de compressão de aproximadamente 75%, evidenciando a eficácia do PCA como uma ferramenta de compressão de imagens. A quantidade de componentes principais utilizadas na

compressão foi destacada como um fator crucial, pois influencia diretamente na recuperação da imagem original a partir da imagem compactada. A taxa de compressão obtida foi um aspecto chave, pois quanto maior a taxa de compressão (menos componentes principais utilizados), maior a degradação da qualidade da imagem recuperada.

Em resumo, o autor ressaltou a importância do PCA como uma abordagem eficaz para a compressão de imagens médicas, proporcionando economia de espaço de armazenamento sem comprometer significativamente a qualidade das imagens. A consideração da quantidade de componentes principais na compressão foi destacada como um aspecto crucial para garantir a recuperação adequada das informações visuais essenciais nas imagens médicas comprimidas.

3.4 COMPRESSÃO DE IMAGENS COM TRANSMISSÃO EM TEMPO REAL

No estudo (SOUSA, 2015), foi adotada a compressão com perdas, onde a qualidade visual da imagem pode ser comprometida em troca de uma maior eficiência na transmissão. Para minimizar o custo computacional exigido, foi escolhida a Transformada de Wavelet discreta de Haar (SOUSA, 2015), que, apesar de não proporcionar a melhor qualidade de imagem, é mais eficiente em termos de processamento, sendo adequada para aplicações em tempo real. A utilização da Transformada de Wavelet de Haar aliada à quantização permitiu a redução da quantidade de dados redundantes na imagem, garantindo uma compressão eficaz. O estudo buscou atender a uma taxa de transmissão de 30 FPS (*frames per second*), o que exigiu a realização da compressão e transmissão de cada imagem em menos de 33,333 milissegundos para assegurar a transmissão em tempo real.

3.5 PROJETO DE ARQUITETURAS INTEGRADAS PARA A COMPRESSÃO DE IMAGENS JPEG

O trabalho (AGOSTINI, 2002) se concentra na compressão de imagens fotográficas digitais, especialmente utilizando o padrão JPEG, amplamente reconhecido e utilizado para a compressão de imagens. A motivação principal é a redução dos dados de imagem para otimizar recursos de armazenamento e transmissão. No sistema de monitoramento de Porto Alegre, as imagens não comprimidas geram altos custos de armazenamento e transporte. Com a compressão JPEG, o sistema poderia aumentar sua capacidade de armazenamento, reduzir custos operacionais e melhorar eficiência geral.

O autor desenvolve arquiteturas específicas para compressão de imagens em *Grays-*

cale e RGB, incluindo a conversão de imagens do espaço de cores RGB para YCbCr. A solução proposta envolve o desenvolvimento de arquiteturas descritas em VHDL, direcionadas para síntese em FPGA's da Altera, permitindo um processamento mais rápido e eficiente. Para imagens em *Grayscale*, a arquitetura pode processar uma imagem de 640x480 pixels em 18.5ms, permitindo uma taxa de 54 imagens por segundo. Para imagens RGB, a arquitetura pode processar uma imagem de 640x480 pixels em 54.4ms, com uma taxa de 18.4 imagens por segundo e uma compressão estimada de 93%.

Em resumo, o autor apresenta uma solução eficiente para a compressão de imagens JPEG, com aplicações potenciais em sistemas de monitoramento de trânsito e outras áreas que demandam processamento rápido e eficiente de imagens. A pesquisa contribui significativamente para a área, pois sugere desenvolve uma forma mais eficiente para comprimir imagens tanto em *Grayscale* quanto em RGB.

4 METODOLOGIA

Neste capítulo, será detalhada a abordagem metodológica adotada para investigar o desempenho dos algoritmos de compressão de imagem PNG, JPEG e PCA no contexto de imagens de tomografia no formato DICOM. A metodologia empregada busca não apenas comparar as taxas de compressão, mas também avaliar o impacto dessa compressão na qualidade das imagens. Para tanto, cada etapa do processo será minuciosamente descrita, desde a coleta e pré-processamento dos dados até a aplicação dos algoritmos de compressão e a análise dos resultados. O foco está em estabelecer uma compreensão clara e fundamentada das vantagens e limitações de cada método em cenários hospitalares.

4.1 BASE DE DADOS

Neste estudo, as imagens de tomografia foram obtidas do *The Cancer Imaging Archive* (TCIA), uma vasta coleção de imagens médicas voltada para pesquisas em oncologia. O TCIA é um recurso público que disponibiliza imagens de alta qualidade, incluindo tomografias computadorizadas, ressonâncias magnéticas, e outros exames, coletados de pacientes com diversos tipos de câncer. O banco de dados é amplamente utilizado para pesquisas acadêmicas e desenvolvimento de algoritmos de análise de imagem.

O TCIA é uma parte do *National Biomedical Imaging Archive* (NBIA), uma iniciativa do *National Institutes of Health* (NIH) dos Estados Unidos. O NBIA foi criado para facilitar o compartilhamento de imagens biomédicas para pesquisa, oferecendo uma plataforma segura e padronizada para o armazenamento e disseminação de imagens médicas. A integração do TCIA ao NBIA garante que as imagens disponibilizadas estejam dentro dos padrões de qualidade e anonimidade exigidos para pesquisas científicas.

4.1.1 Classificação das imagens

Para este estudo, foram selecionadas 15.000 imagens de tomografia computadorizada de diferentes coleções de imagens do TCIA, todas no formato DICOM. Essas imagens foram separadas em três tipos de câncer:

- **Câncer de Mama:** As 5.000 imagens de câncer de mama foram adquiridas da coleção *Abbreviated Breast MRI and Digital Tomosynthesis Mammography in Screening Women With Dense Breasts* (EA1141) (COMSTOCK *et al.*, 2023). As imagens de mama geral-

mente contém uma proporção significativa de tecido denso e menos espaços vazios, o que pode dificultar a compressão em relação a outros órgãos.

- **Câncer de Pulmão:** Foram selecionadas 5.000 imagens de tomografia computadorizada da coleção *NSCLC-Radiomics* (NSCLC) (AERTS *et al.*, 2014). O pulmão, por sua anatomia, possui grandes espaços de ar, o que pode facilitar a compressão devido à presença de áreas de baixa densidade.
- **Câncer Cerebral:** As 5.000 imagens de câncer cerebral foram adquiridas da coleção *The Brain Resection Multimodal Imaging Database* (REMIND) (JUVEKAR *et al.*, 2023). O cérebro, por ser um órgão com alta densidade de estruturas e pouca presença de espaço vazio, pode apresentar um comportamento de compressão distinto em comparação com os pulmões.

A escolha de diferentes tipos de câncer foi feita com o intuito de testar a eficácia dos métodos de compressão em órgãos com tamanhos e disposições espaciais variáveis. A presença de diferentes proporções de espaços vazios, como os encontrados no pulmão em comparação com o cérebro, permite uma análise comparativa mais robusta, uma vez que a densidade e a estrutura de cada órgão podem impactar diretamente nas taxas de compressão. Essa diversidade de imagens é essencial para verificar o comportamento dos algoritmos de compressão (PNG, JPEG e PCA) em cenários distintos, fornecendo uma visão ampla sobre a aplicabilidade desses métodos em ambientes hospitalares com uma variedade de exames de imagem.

4.1.2 Transfer Syntax UID

O campo *Transfer Syntax UID* dentro de um arquivo DICOM é utilizado para definir o método de codificação dos dados da imagem, incluindo se há ou não compressão. As três coleções de imagens utilizadas não especificam se as imagens fornecidas possuem ou não compressão, então, para garantir que as imagens utilizadas neste estudo não estivessem previamente comprimidas, foi executado um script (desenvolvido pelo autor) para verificar os *Transfer Syntax UIDs* associados a cada arquivo DICOM.

Abaixo estão descritos alguns dos principais UIDs utilizados em arquivos DICOM para imagens comprimidas e não comprimidas:

Imagens sem compressão Imagens DICOM que não passaram por compressão podem ser identificadas pelos seguintes UIDs:

- **1.2.840.10008.1.2** – Implicit VR LittleEndian: formato não comprimido, codificado com

LittleEndian e sem representação explícita de VR (Value Representation).

- **1.2.840.10008.1.2.1** – Explicit VR LittleEndian: formato não comprimido, codificado com *LittleEndian*, e com representação explícita de VR.
- **1.2.840.10008.1.2.2** – Explicit VR BigEndian: formato não comprimido, codificado com *BigEndian*, e com representação explícita de VR.

Imagens com compressão Para imagens que foram comprimidas, diferentes UIDs são utilizados, dependendo do tipo de compressão aplicada. Abaixo estão alguns dos UIDs mais comuns para compressão:

- **1.2.840.10008.1.2.4.50** – JPEG Baseline (Processo 1): compressão JPEG com perdas.
- **1.2.840.10008.1.2.4.51** – JPEG Extended (Processos 2 e 4): compressão JPEG com perdas estendida.
- **1.2.840.10008.1.2.4.57** – JPEG Lossless (Processo 14, Seleção de Hierarquia de Previsão 1): compressão JPEG sem perdas.
- **1.2.840.10008.1.2.4.70** – JPEG Lossless (Processo 14): compressão JPEG sem perdas.
- **1.2.840.10008.1.2.4.80** – JPEG-LS Lossless Image Compression: compressão JPEG-LS sem perdas.
- **1.2.840.10008.1.2.4.81** – JPEG-LS Near-Lossless Image Compression: compressão JPEG-LS com perdas leves.
- **1.2.840.10008.1.2.4.90** – JPEG 2000 Lossless: compressão JPEG 2000 sem perdas.
- **1.2.840.10008.1.2.4.91** – JPEG 2000 com perdas: compressão JPEG 2000 com perdas.
- **1.2.840.10008.1.2.5** – RLE (Run-Length Encoding): compressão RLE, um método de compressão sem perdas.
- **1.2.840.10008.1.2.6.1** – Deflated Explicit VR LittleEndian: compressão deflacionada para dados explícitos *LittleEndian*.
- **1.2.840.10008.1.2.1.99** – Deflated Explicit VR LittleEndian: compressão baseada no método *zlib* (sem perdas).

Esses UIDs são essenciais para verificar a presença ou ausência de compressão em imagens médicas (LIBRARY, 2023). No presente estudo, as imagens utilizadas foram verificadas para garantir que não houvesse compressão anterior à aplicação dos métodos de compressão propostos (PNG, JPEG e PCA), utilizando o *Transfer Syntax UID 1.2.840.10008.1.2* (Implicit VR LittleEndian) para imagens sem compressão.

4.2 DEFINIÇÃO DOS CENÁRIOS

4.2.1 Pré-processamento

Para cada tipo de órgão (pulmão, mama e cérebro), foi executado um script para filtrar as imagens DICOM que não estavam comprimidas, ou seja, aquelas cujo valor do *Transfer Syntax UID* correspondia a um dos mencionados no tópico anterior. Este filtro assegurou que somente imagens sem compressão fossem consideradas para o estudo, permitindo uma avaliação precisa do impacto dos algoritmos de compressão aplicados.

Em seguida, dentre as imagens não comprimidas, foram selecionadas aquelas com resolução de 512×512 pixels. A escolha desta resolução se justifica por ser uma das mais comuns em imagens de tomografia computadorizada, garantindo uniformidade nos dados e facilitando a comparação entre os resultados dos diferentes algoritmos. Além disso, esta resolução oferece um equilíbrio adequado entre detalhamento da imagem e tamanho do arquivo (HSIEH, 2003), aspecto relevante para o armazenamento em sistemas hospitalares.

Após o processo de filtragem, foi obtido um conjunto de 5.000 imagens de cada órgão, todas com resolução de 512×512 pixels e sem compressão. Este conjunto de dados homogêneo serviu como base para a aplicação e avaliação dos algoritmos de compressão selecionados.

4.2.2 Processamento

Foram implementados três algoritmos de compressão de imagem: PNG (sem perda), JPEG (com perda) e PCA (Análise de Componentes Principais, com perda). Para percorrer e comprimir todas as imagens, foi utilizada a biblioteca *Pillow* (CLARK; CONTRIBUTORS, 2023) para os formatos PNG e JPEG, e a biblioteca *scikit-learn* (PEDREGOSA *et al.*, 2011) para o PCA.

Antes da compressão, todas as imagens foram normalizadas para o formato `uint8`, com pixels no intervalo de 0 a 255. Esta normalização é fundamental para padronizar os dados de entrada dos algoritmos de compressão e assegurar que diferenças de escala não influenciem os resultados. Além disso, o formato `uint8` é amplamente utilizado em processamento de imagens, otimizando o desempenho computacional e o uso de memória (GONZALEZ; WOODS, 2008).

No caso do PCA, o algoritmo foi parametrizado pela porcentagem de variância explicada, utilizando valores de 95%, 97,5% e 99%. Foi optado por parametrizar desta forma ao invés de especificar o número de componentes principais, pois em imagens médicas em tons de

cinza, frequentemente apenas um componente já captura a maior parte da variância (devido ao alto contraste entre regiões de interesse e o fundo). Isto é particularmente relevante em imagens de tomografia, que apresentam grandes áreas com pouca informação (espaço vazio), tornando a variância explicada um critério mais adequado para determinar a quantidade de informação retida.

As imagens comprimidas pelo PCA foram armazenadas no formato npz, que permite salvar arrays NumPy (HARRIS *et al.*, 2020) de forma compacta e eficiente. Neste formato, foram armazenados a imagem comprimida (projeções nos componentes principais), os componentes principais (matriz de carregamentos) e a média utilizada no processo de centralização dos dados. O uso do npz facilita o armazenamento e a recuperação dos dados necessários para reconstruir as imagens, além de ser um formato otimizado para operações com arrays numéricos.

4.2.3 Avaliação da Qualidade das Imagens

Para medir a qualidade aparente das imagens após a compressão, cada imagem comprimida foi comparada com sua correspondente original. Foi calculado o *Mean Squared Error* (MSE) entre as duas imagens e, a partir deste valor, foi obtido o *Peak Signal-to-Noise Ratio* (PSNR). O PSNR é uma métrica amplamente utilizada para quantificar a qualidade de reconstrução em imagens comprimidas, onde valores mais altos indicam maior fidelidade em relação à imagem original.

As faixas de qualidade do PSNR são interpretadas da seguinte forma:

- Acima de 40 dB: qualidade excelente, diferenças imperceptíveis ao olho humano.
- Entre 30 e 40 dB: qualidade boa, diferenças mínimas percebidas.
- Entre 20 e 30 dB: qualidade razoável, diferenças perceptíveis.
- Abaixo de 20 dB: qualidade baixa, perda significativa de detalhes.

Quadro 1 – Resumo detalhado das etapas da metodologia.

Etapa	Descrição
Filtro de Imagens DICOM	Seleção das imagens sem compressão utilizando o <i>Transfer Syntax UID</i> como critério de filtragem.
Filtragem por Resolução	Seleção de imagens com resolução de 512×512 pixels, garantindo uniformidade nos dados.
Normalização dos Dados	Conversão das imagens para o formato <code>uint8</code> , ajustando os valores dos pixels para o intervalo de 0 a 255.
Compressão com PNG	Aplicação do algoritmo PNG, garantindo compressão sem perda de qualidade.
Compressão com JPEG	Aplicação do algoritmo JPEG, obtendo altas taxas de compressão com perda controlada.
Compressão com PCA	Aplicação do algoritmo PCA, utilizando percentuais de variância explicada (95%, 97,5% e 99%).
Armazenamento PCA	Salvamento dos resultados do PCA no formato <code>npz</code> , incluindo a imagem comprimida, componentes principais e média.
Avaliação da Qualidade	Cálculo do MSE e do PSNR para comparar as imagens comprimidas com as originais.
Registro de Resultados	Organização dos dados em planilhas contendo valores de MSE, PSNR e taxas de compressão.
Geração de Gráficos	Criação de gráficos comparativos das taxas de compressão e PSNR, segmentados por órgão e algoritmo.

Fonte: Elaborado pelo autor.

5 RESULTADOS

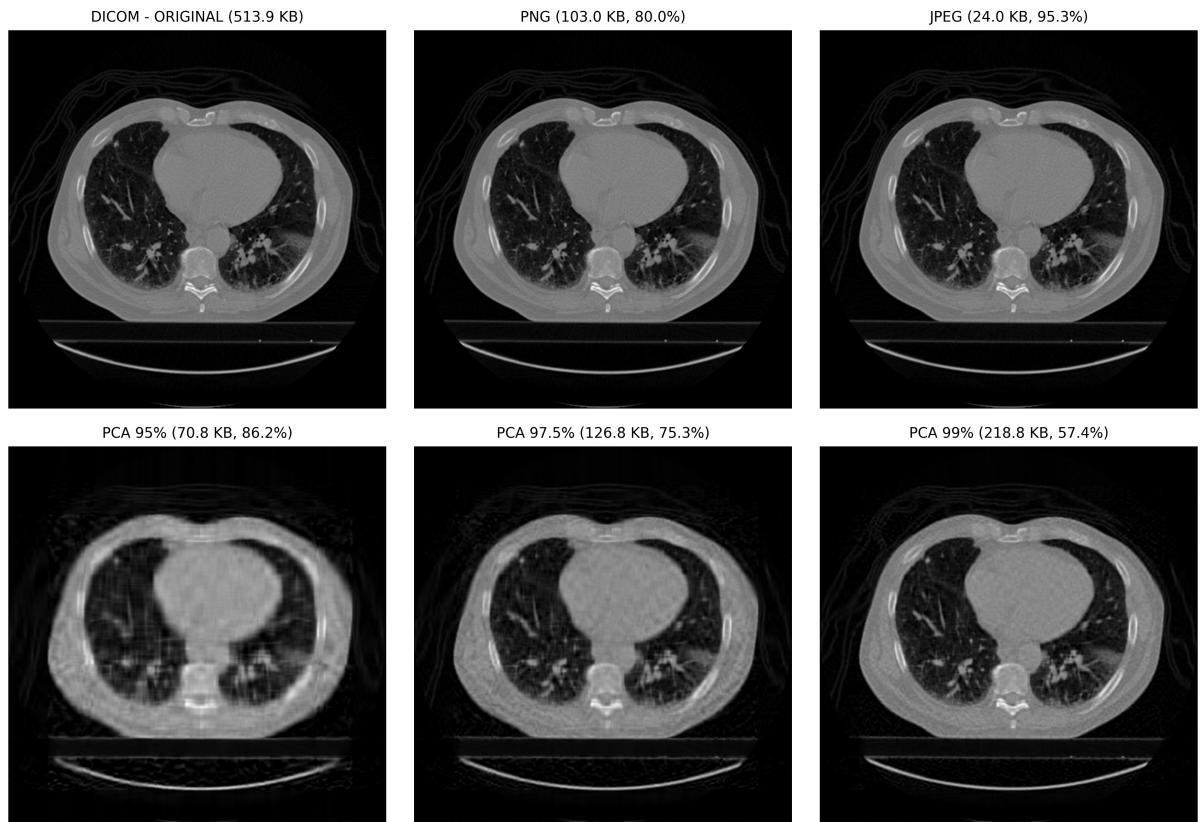
Neste capítulo, são apresentados os resultados da compressão de imagens DICOM dos órgãos pulmão, mama e cérebro utilizando os algoritmos PNG, JPEG e PCA (com diferentes níveis de variância explicada). Inicialmente, é feita uma análise qualitativa com comparações visuais entre uma imagem original e suas versões comprimidas. Em seguida, são apresentadas as análises quantitativas das taxas de compressão e da qualidade aparente (PSNR), agrupadas por algoritmo e tipo de órgão.

5.1 COMPARAÇÃO VISUAL DAS IMAGENS

Nas Figuras 11, 12 e 13, são apresentadas as comparações visuais entre as imagens originais e suas versões comprimidas por cada método. Essas comparações permitem observar o impacto visual de cada método de compressão, considerando diferentes tipos de órgãos.

- **Pulmão:** Na Figura 11, é apresentada a comparação visual das imagens de pulmão. Essas imagens possuem áreas homogêneas que favorecem altas taxas de compressão em todos os métodos, resultando em perdas visuais mínimas mesmo em cenários de maior redução, como no JPEG e no PCA.

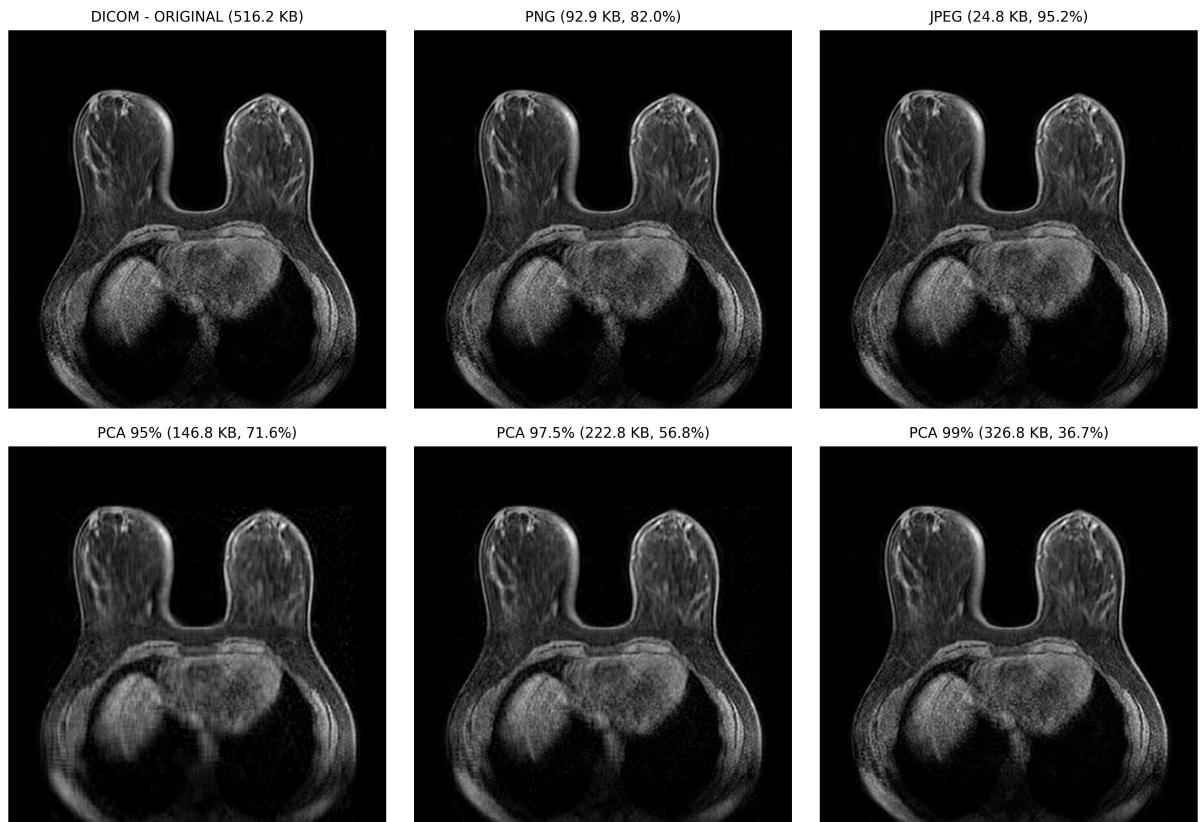
Figura 11 – Comparação visual das imagens de pulmão: original e comprimidas por PNG, JPEG e PCA.



Fonte: Elaborado pelo autor.

- **Mama:** A Figura 12 apresenta as imagens de mama, que possuem alta densidade de detalhes. Essa característica dificultou a compressão, especialmente em cenários de maior redução, como o PCA em 95%, resultando em perdas mais perceptíveis visualmente.

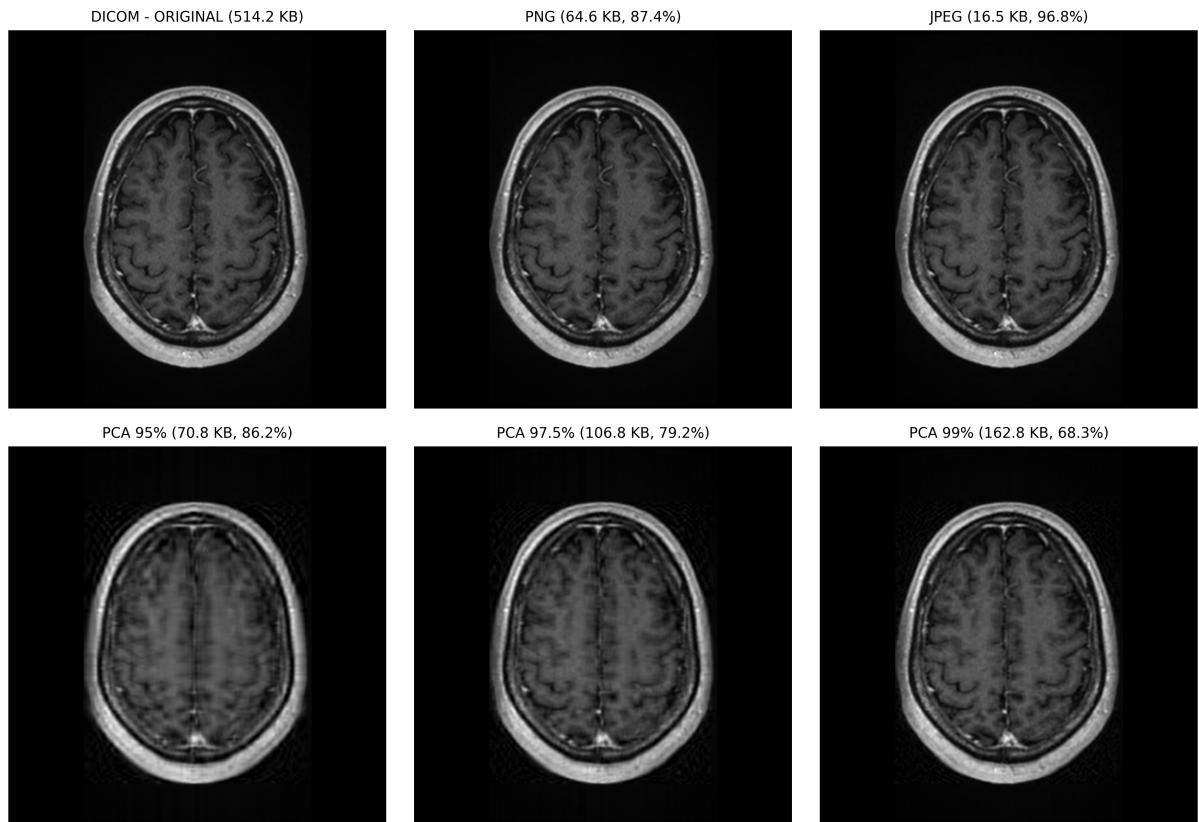
Figura 12 – Comparação visual das imagens de mama: original e comprimidas por PNG, JPEG e PCA.



Fonte: Elaborado pelo autor.

- **Cérebro:** Na Figura 13, observa-se as imagens de cérebro, que possuem uma combinação equilibrada entre áreas homogêneas e detalhadas. Essa característica resultou em compressões intermediárias, com perdas visuais moderadas dependendo do método e dos parâmetros utilizados, como observado no PCA.

Figura 13 – Comparação visual das imagens de cérebro: original e comprimidas por PNG, JPEG e PCA.



Fonte: Elaborado pelo autor.

Estas figuras destacam que o método PNG é ideal para preservação completa de qualidade, enquanto o JPEG e o PCA oferecem maior flexibilidade entre compressão e qualidade visual, dependendo dos parâmetros utilizados.

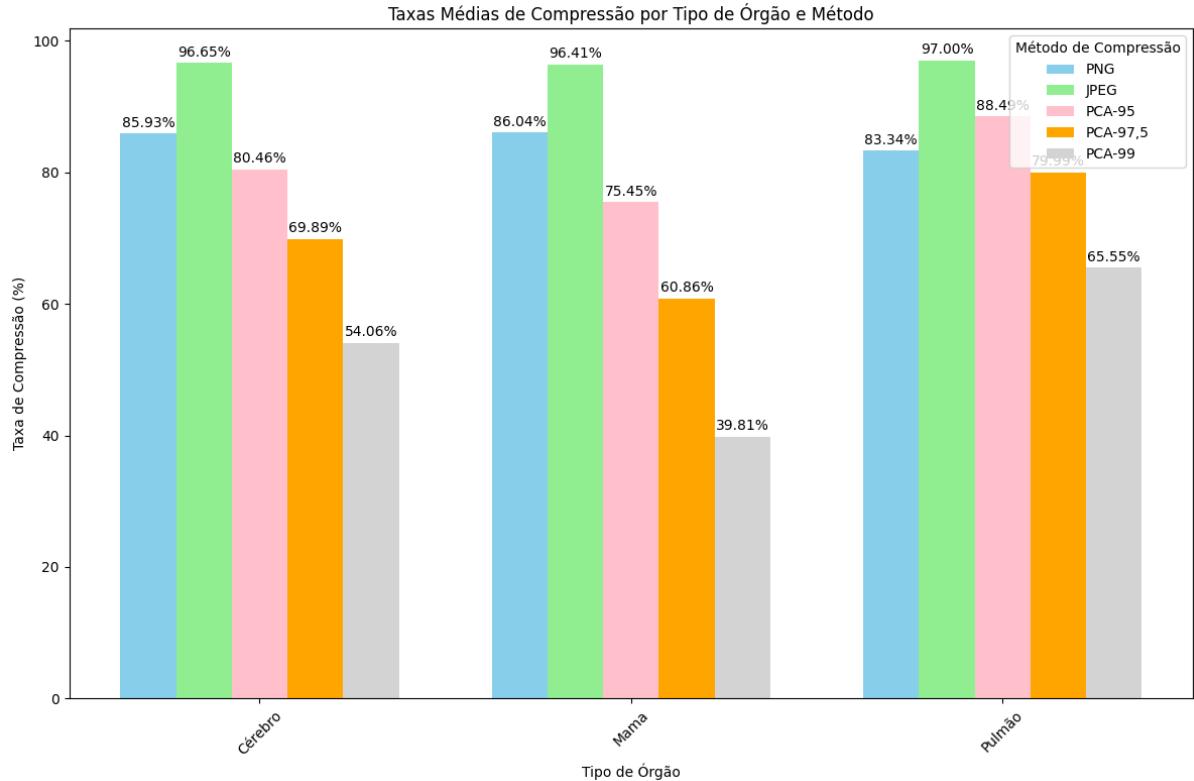
5.2 TAXAS DE COMPRESSÃO

As taxas médias de compressão obtidas por cada algoritmo, agrupadas por tipo de órgão, estão apresentadas na Figura 14. Observa-se que:

- O algoritmo **JPEG** alcançou as maiores taxas de compressão em todos os órgãos, superando 96%.
- O **PNG**, embora sem perdas, apresentou taxas de compressão em torno de 83-86%, destacando-se pela capacidade de obter uma alta taxa de compressão mesmo sem ter perdas de informações.
- O **PCA** teve desempenho variável conforme o percentual de variância explicada. À medida que a variância aumenta (de 95% para 99%), a taxa de compressão diminui, o que é

esperado devido ao aumento na retenção de detalhes.

Figura 14 – Taxas médias de compressão por tipo de órgão e método de compressão.



Fonte: Elaborado pelo autor

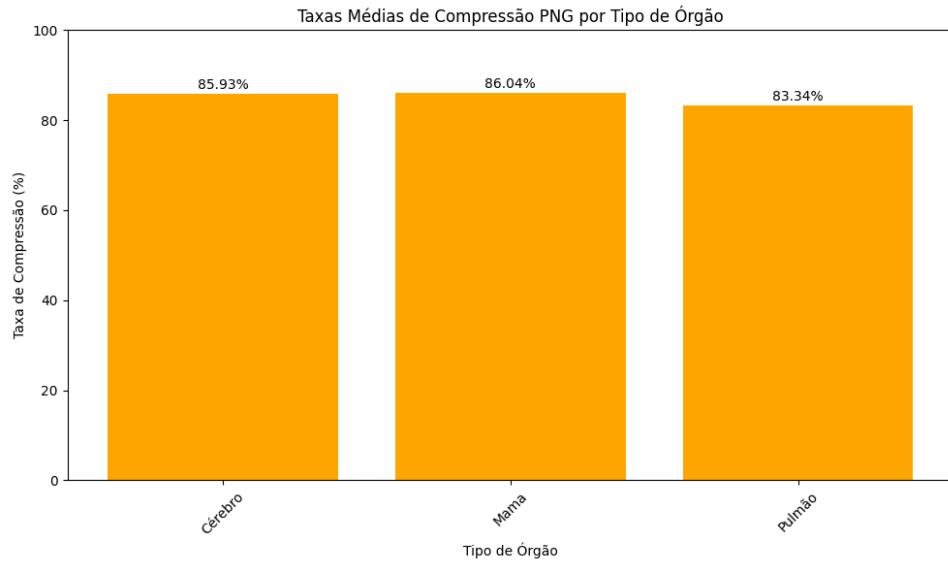
5.3 TAXAS DE COMPRESSÃO POR MÉTODO

Para uma análise detalhada por algoritmo, foram gerados gráficos específicos para cada método, conforme apresentado a seguir:

5.3.1 PNG

As taxas médias de compressão do PNG estão ilustradas na Figura 15. O desempenho foi uniforme entre os órgãos, com taxas variando entre 83% e 86%.

Figura 15 – Taxas médias de compressão PNG por tipo de órgão.

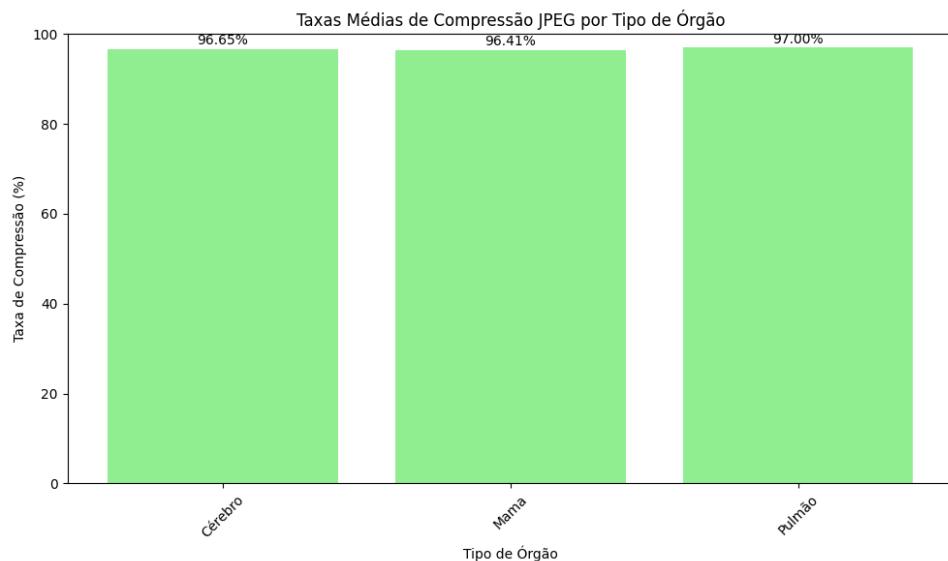


Fonte: Elaborado pelo autor

5.3.2 JPEG

A Figura 16 apresenta as taxas médias de compressão para o JPEG. Este método apresentou as melhores taxas de compressão entre quase todos os algoritmos, alcançando valores superiores a 97%.

Figura 16 – Taxas médias de compressão JPEG por tipo de órgão.



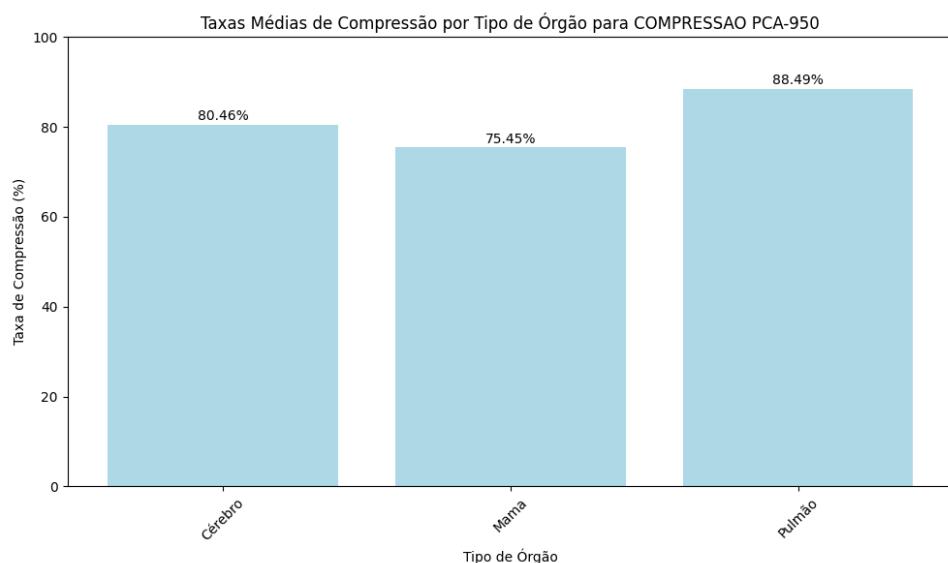
Fonte: Elaborado pelo autor

5.3.3 PCA

As taxas médias de compressão para o PCA são apresentadas nas Figuras 17, 18 e 19, referentes aos percentuais de variância explicada de 95%, 97,5% e 99%, respectivamente. Observa-se que:

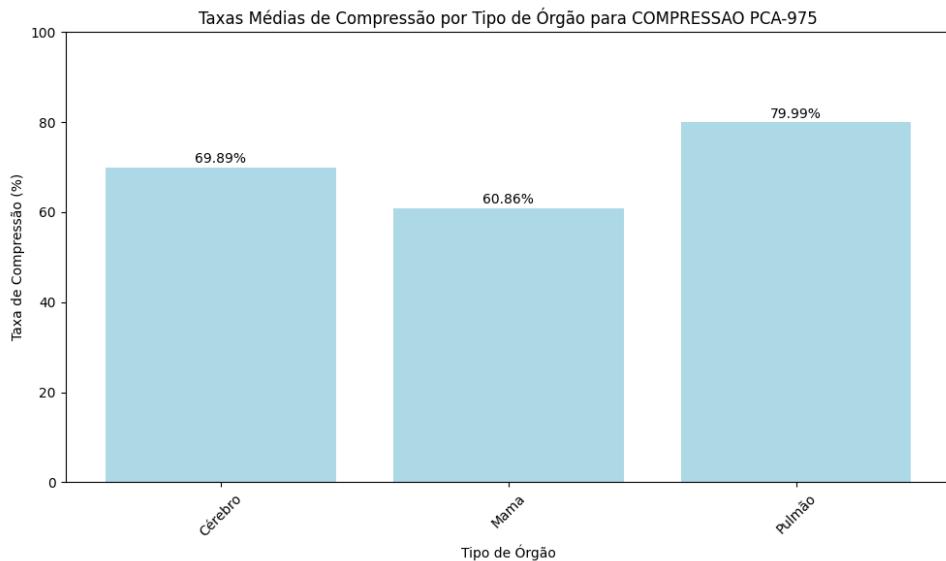
- A compressão diminui à medida que aumenta o percentual de variância explicada, devido à retenção de mais detalhes.
- Órgãos com maior densidade de pixels (como pulmão) apresentam maior compressão, pois possuem mais áreas uniformes que facilitam a aplicação do PCA.

**Figura 17 – Taxas médias de compressão por tipo de órgão para o PCA
(95% de variância explicada).**



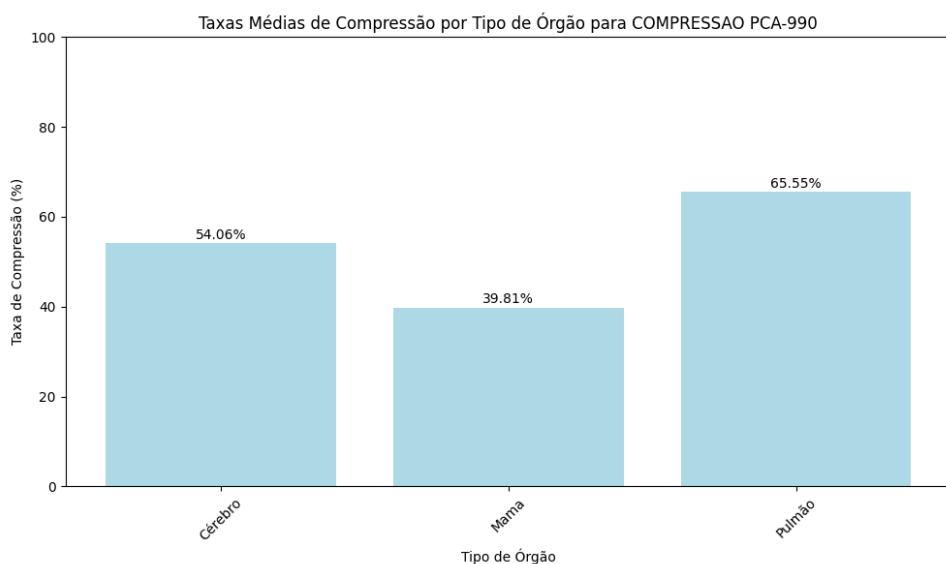
Fonte: Elaborado pelo autor

**Figura 18 – Taxas médias de compressão por tipo de órgão para o PCA
(97,5% de variância explicada).**



Fonte: Elaborado pelo autor

**Figura 19 – Taxas médias de compressão por tipo de órgão para o PCA
(99% de variância explicada).**



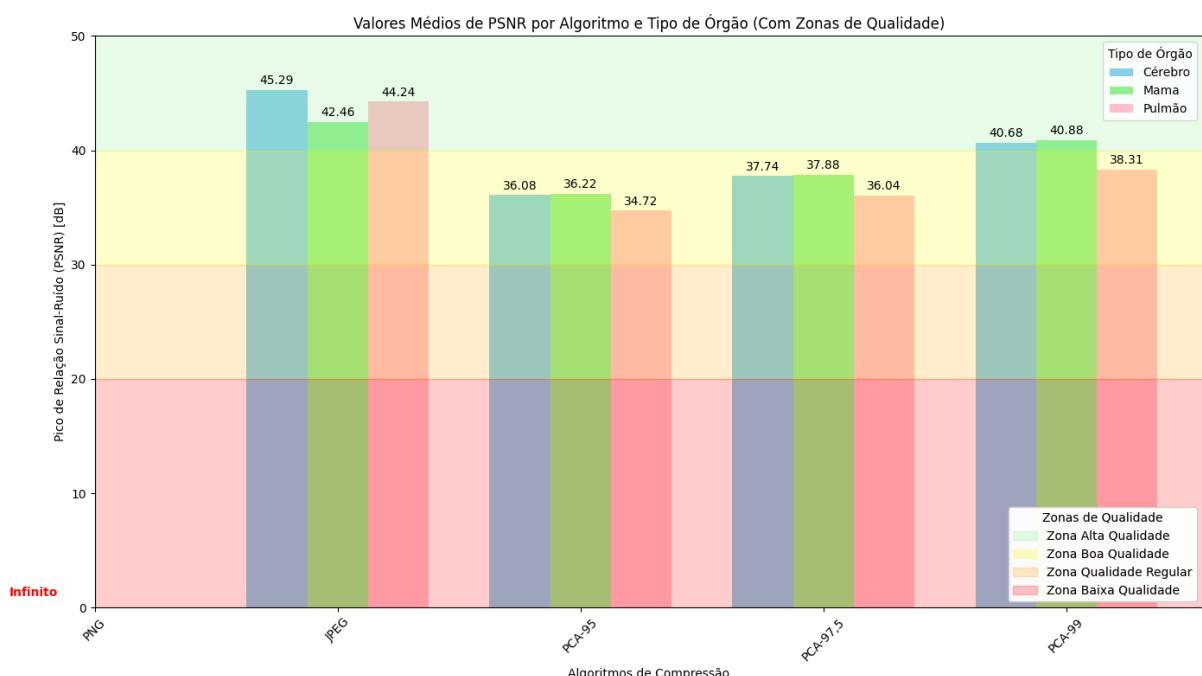
Fonte: Elaborado pelo autor

5.4 ANÁLISE DE QUALIDADE APARENTE (PSNR)

Os valores médios de PSNR obtidos estão apresentados na Figura 20. Observa-se que:

- O **PNG** apresentou valores que tendem ao infinito, uma vez que é um método sem perda logo o MSE resulta em 0, indicando qualidade visual idêntica à imagem original.
- O **JPEG** manteve valores entre 42 e 45 dB, indicando uma alta qualidade, embora com perdas.
- O **PCA** apresentou valores mais baixos para os percentuais de variância explicada de 95% e 97,5%, enquanto o PCA-99% manteve valores próximos a 40 dB, destacando-se pela retenção de maior qualidade visual.

Figura 20 – Valores médios de PSNR por algoritmo e tipo de órgão.



Fonte: Elaborado pelo autor

5.5 DISCUSSÃO DOS RESULTADOS

Os resultados obtidos indicam que a escolha do algoritmo de compressão depende do objetivo:

- O **PNG** preserva integralmente a qualidade visual da imagem original, sendo indicado para casos onde a preservação completa da qualidade é imprescindível, como em aplicações críticas para diagnóstico médico. Este resultado é esperado, dado que o PNG é um método de compressão sem perda, apresentando taxas de compressão consistentes e eficiência em manter a integridade das informações.
- O **JPEG** é ideal para maximizar a compressão, mesmo com uma pequena perda de

qualidade visual. Este método apresenta pequenas perdas de detalhes em áreas com maior densidade de informação (ex.: bordas e transições), mas as diferenças visuais são mínimas, tornando-o adequado para armazenamento de longo prazo e situações onde a redução significativa de tamanho é prioritária.

- O **PCA** oferece flexibilidade, permitindo ajustar o nível de compressão com base na variância explicada. No entanto, as diferenças visuais aumentam conforme o nível de variância explicada diminui, sendo que imagens comprimidas com 95% de variância apresentam degradação visível em áreas de maior contraste. Em contrapartida, versões com 99% de variância preservam melhor os detalhes visuais, ainda que com menor taxa de compressão. Esse método também requer maior processamento para reconstruir as imagens, o que deve ser considerado em contextos práticos.

A variação entre os órgãos pode ser atribuída às características específicas das imagens:

- O **pulmão**, caracterizado por grandes áreas homogêneas devido à presença de espaços vazios (pretos) nas imagens de tomografia, favoreceu a compressão eficiente em todos os algoritmos. Essa característica reduz a complexidade da imagem, permitindo que métodos como o PCA e o JPEG explorem a redundância dos dados para alcançar altas taxas de compressão sem comprometer significativamente a qualidade visual.
- A **mama**, devido à sua alta densidade de detalhes e à textura mais heterogênea distribuída por toda a imagem, apresentou maior dificuldade para compressão. Essa complexidade aumenta a quantidade de informação que precisa ser mantida, especialmente para métodos como o PCA, que depende de uma separação clara entre componentes principais e ruído. Como resultado, as taxas de compressão foram menores e as perdas de qualidade mais perceptíveis.
- O **cérebro**, com características intermediárias, combina áreas homogêneas, como o fundo da imagem, com regiões mais detalhadas, como o córtex cerebral. Essa composição balanceada permitiu que os algoritmos alcançassem resultados intermediários tanto em taxas de compressão quanto em qualidade visual. Enquanto o fundo homogêneo facilita a compressão, as regiões detalhadas impõem desafios que moderam o desempenho global dos algoritmos.

Esses resultados contribuem para a definição de estratégias eficientes de compressão em ambientes hospitalares, levando em consideração as características específicas das imagens médicas de cada órgão.

6 CONCLUSÃO

Neste trabalho, foi realizada uma análise comparativa de três métodos de compressão de imagens médicas no formato DICOM: PNG, JPEG e PCA. O estudo investigou o impacto desses algoritmos na redução do tamanho dos arquivos e na preservação da qualidade das imagens médicas, considerando três tipos de órgãos: pulmão, mama e cérebro. Os resultados demonstraram diferenças significativas entre os métodos, evidenciando vantagens e limitações que dependem tanto das características dos algoritmos quanto do conteúdo das imagens.

As questões de pesquisa levantadas foram abordadas de maneira detalhada. Primeiramente, quanto às taxas médias de compressão alcançadas pelos algoritmos, o JPEG obteve os melhores resultados, superando 96% em todos os órgãos analisados. O PNG apresentou taxas moderadas e consistentes de 83-86%, conciliando uma alta taxa de compressão com preservação total da qualidade. Já o PCA demonstrou um desempenho variável, dependendo do percentual de variância explicada, sendo mais eficiente em cenários onde a retenção parcial da informação é aceitável.

Sobre o impacto das características das imagens de cada órgão nas taxas de compressão, foi constatado que imagens de pulmão, devido às suas grandes áreas homogêneas, favoreceram a compressão em todos os algoritmos, resultando nas melhores taxas. Por outro lado, as imagens de mama, com maior densidade de detalhes, apresentaram maior resistência à compressão. As imagens de cérebro, por sua vez, exibiram comportamento intermediário, refletindo sua composição equilibrada entre áreas homogêneas e detalhadas.

Em relação ao impacto da variação da taxa de compressão na qualidade visual, os valores de PSNR demonstraram que o PNG manteve a qualidade perfeita das imagens, com PSNR tendendo ao infinito. O JPEG apresentou valores entre 42 e 45 dB, indicando alta qualidade visual com perdas imperceptíveis a olho nu. Já o PCA, dependendo do percentual de variância explicada, teve qualidade mais variável, com melhores resultados observados em níveis mais altos (99%).

Finalmente, no que diz respeito à escolha do algoritmo ideal para cada cenário, conclui-se que o JPEG oferece o melhor equilíbrio entre compressão e qualidade visual, sendo uma opção eficiente para armazenamento em larga escala. O PNG é recomendado para aplicações que exigem preservação total da qualidade, enquanto o PCA é mais indicado para cenários onde a flexibilidade na retenção de dados é prioritária, apesar de seu maior custo computacional.

Este estudo contribui para o entendimento das particularidades de cada método de

compressão e oferece subsídios para a escolha de estratégias adequadas em diferentes cenários hospitalares. Como trabalhos futuros, sugere-se:

- Avaliar outros algoritmos de compressão, como AVIF e SPIHT, que também são amplamente utilizados em imagens médicas e científicas.
- Explorar métodos baseados em aprendizado de máquina, como compressão neural.
- Investigar o impacto da compressão na acurácia de diagnósticos realizados a partir dessas imagens com o auxílio de um profissional da saúde especializado em diagnóstico de imagens médicas.
- Ampliar o estudo para outros tipos de exames médicos, como ressonância magnética e ultrassonografia, a fim de verificar se os resultados observados neste trabalho se mantêm em outros contextos.

Com base nos resultados obtidos, conclui-se que a compressão de imagens médicas, quando bem planejada, pode oferecer soluções eficazes para os desafios de armazenamento em ambientes hospitalares, conciliando redução de tamanho e preservação da integridade das informações essenciais ao diagnóstico.

REFERÊNCIAS

AERTS, H. J. W. L.; WEE, L.; VELAZQUEZ, E. R.; LEIJENAAR, R. T. H.; PARMAR, C.; GROSSMANN, P.; CARVALHO, S.; BUSSINK, J.; MONSHOUWER, R.; HAIBE-KAINS, B.; RIETVELD, D.; HOEBERS, F.; RIETBERGEN, M. M.; LEEMANS, C. R.; DEKKER, A.; QUACKENBUSH, J.; GILLIES, R. J.; LAMBIN, P. **Data From NSCLC-Radiomics (version 4)**. The Cancer Imaging Archive, 2014. Disponível em: <<https://doi.org/10.7937/K9/TCIA.2015.PF0M9REI>>.

AGOSTINI, L. V. **Projeto de arquiteturas integradas para a compressão de imagens JPEG**. Dissertação (Mestrado) — Universidade Federal do Rio Grande do Sul. Instituto de Informática. Programa de Pós-Graduação em Computação, 2002. Disponível em: <<https://lume.ufrgs.br/handle/10183/11431>>.

ANON. **Lossless Compression - Lossy and Lossless**. 2024. [Online; accessed 5-June-2024]. Disponível em: <<https://lossyandlossless.weebly.com/lossless-compression.html>>.

BIRADAR, R.; MAKANDAR, A. Analysis of 3d medical image compression. **International Research Journal of Modernization in Engineering Technology and Science**, IRJMETS, v. 4, n. 12, p. 9, 2022. Disponível em: <https://www.irjmets.com/uploadedfiles/paper/issue_12_december_2022/31876/final/fin_irjmets1670230344.pdf>.

CHAUDHARY, A. K.; MEHROTRA, R.; ANSARI, M. A.; TRIPATHI, P. A novel scheme for medical image compression using huffman and dct techniques. Springer Singapore, Singapore, p. 289–300, 2021.

CLARK, A.; CONTRIBUTORS. **Pillow: The Friendly PIL Fork**. 2023. <<https://pillow.readthedocs.io/en/stable/>>.

COMSTOCK, C. E.; GATSONIS, C.; NEWSTEAD, G. M.; SNYDER, B. S.; GAREEN, I. F.; BERGIN, J. T.; RAHBAR, H.; SUNG, J. S.; JACOBS, C.; HARVEY, J. A.; NICHOLSON, M. H.; WARD, R. C.; HOLT, J.; PRATHER, A.; MILLER, K. D.; SCHNALL, M. D.; KUHL, C. K. **Abbreviated Breast MRI and Digital Tomosynthesis Mammography in Screening Women With Dense Breasts (EA1141) (Version 1)**. The Cancer Imaging Archive, 2023. Disponível em: <<https://doi.org/10.7937/2BAS-HR33>>.

DILLON, W.; GOLDSTEIN, M. **Multivariate Analysis: Methods and Applications**. Wiley, 1984. (Wiley Series in Probability and Statistics). ISBN 9780471083177. Disponível em: <<https://books.google.com.br/books?id=nrbvAAAAMAAJ>>.

DIMILILER, K. Dct-based medical image compression using machine learning. **Signal, Image and Video Processing**, v. 16, n. 1, p. 55–62, February 2022. Disponível em: <<https://doi.org/10.1007/s11760-021-01951-0>>.

ELAKKIYA, S.; THIVYA, K. S. Comprehensive review on lossy and lossless compression techniques. **Journal of The Institution of Engineers (India): Series B**, v. 103, p. 1003–1012, 2021.

FEOFILOFF, P. **Árvores binárias**. Instituto de Matemática e Estatística da Universidade de São Paulo (IME-USP), 2018. Disponível em: <<https://www.ime.usp.br/~pf/algoritmos/aulas/bint.html>>.

GONZALEZ, R. C.; WOODS, R. E. **Digital Image Processing**. [S.I.]: Pearson Education, 2008.

HARRIS, C. R.; MILLMAN, K. J.; WALT, S. J. van der; GOMMERS, R.; VIRTANEN, P.; COURNAPEAU, D.; WIESER, E.; TAYLOR, J.; BERG, S.; SMITH, N. J.; KERN, R.; PICUS, M.; HOYER, S.; KERKWIJK, M. H. van; BRETT, M.; HALDANE, A.; RÍO, J. Fernández del; WIEBE, M.; PETERSON, P.; GÉRARD-MARCHANT, P.; SHEPPARD, K.; REDDY, T.; WECKESSER, W.; ABBASI, H.; GOHLKE, C.; OLIPHANT, T. E. **NumPy: The fundamental package for array computing with Python.** 2020. 357–362 p. Disponível em: <<https://numpy.org/doc/stable/>>.

HSIEH, J. Computed tomography: principles, design, artifacts, and recent advances. SPIE press, 2003.

HUFFMAN, D. A. A method for the construction of minimum-redundancy codes. **Proceedings of the IRE**, v. 40, n. 9, p. 1098–1101, 1952. Disponível em: <https://compression.ru/download/articles/huff/huffman_1952_minimum-redundancy-codes.pdf>.

JAVATPOINT. **Huffman Coding using Python - Javatpoint.** 2021. Disponível em: <<https://www.javatpoint.com/huffman-coding-using-python>>.

JUVEKAR, P.; DORENT, R.; KöGL, F.; TORIO, E.; BARR, C.; RIGOLO, L.; GALVIN, C.; JOWKAR, N.; KAZI, A.; HAOUCHINE, N.; CHEEMA, H.; NAVAB, N.; PIEPER, S.; WELLS, W. M.; BI, W. L.; GOLBY, A.; FRISKEN, S.; KAPUR, T. **The Brain Resection Multimodal Imaging Database (ReMIND) (Version 1).** The Cancer Imaging Archive, 2023. Disponível em: <<https://doi.org/10.7937/3RAG-D070>>.

LI, Y.; XU, Z.; LIU, X.; SASI, G.; BALAJI, M. S. P.; JEGADEESAN, N.; DEVASENA, L.; BALAJI, V. S.; ELAMARAN, V. Exploring digital image dithering techniques on a broken foot image. **Journal of Medical Imaging and Health Informatics**, v. 10, n. 9, p. 2247–2251, 2020. ISSN 2156-7018. Disponível em: <<https://www.ingentaconnect.com/content/asp/jmhi/2020/00000010/00000009/art00045>>.

LIBRARY, D. **DICOM Transfer Syntax UIDs.** 2023. Disponível em: <<https://www.dicomlibrary.com/dicom/transfer-syntax>>.

MARQUES, J.; HONÓRIO, T.; POEL, J.; SOUZA, A.; BATISTA, L. Compressão sem perdas de imagens mamográficas utilizando código gray e algoritmo ppm. In: _____. [S.l.: s.n.], 2007. v. 18, p. 1216–1220. ISBN 978-3-540-74470-2.

MIANO, J. **Compressed image file formats: Jpeg, png, gif, xbm, bmp.** [S.l.]: Addison-Wesley Professional, 1999.

NEMA. **DICOM PS3.1 - Introduction and Overview.** 2016. Disponível em: <https://dicom.nema.org/medical/dicom/2016a/output/pdf/part01_changes.pdf>.

PEDREGOSA, F.; VAROQUAUX, G.; GRAMFORT, A.; MICHEL, V.; THIRION, B.; GRISEL, O.; BLONDEL, M.; PRETTENHOFER, P.; WEISS, R.; DUBOURG, V.; VANDERPLAS, J.; PASSOS, A.; COURNAPEAU, D.; BRUCHER, M.; PERROT, M.; DUCHESNAY, E. **scikit-learn: Machine Learning in Python.** 2011. 2825–2830 p. Disponível em: <<https://scikit-learn.org/stable/>>.

SANTO, R. do E. Utilização da análise de componentes principais na compressão de imagens digitais. **einstein (São Paulo)**, v. 10, n. 2, p. 135–139, 2012. ISSN 1679-4508. Disponível em: <https://journal.einstein.br/article/principal-component-analysis-applied-to-digital-image-compression>.

- SAYOOD, K. **Introduction to Data Compression.** [S.l.]: Academic Press, 2006.
- SILVA, L. A. B.; COSTA, C. M. A. **Medical imaging services supported on cloud.** Aveiro: L. Silva, 2011. Disponível em: <<http://hdl.handle.net/10773/7245>>.
- SOUZA, R. C. A. de. **Compressão de imagens com transmissão em tempo real.** Tese (Doutorado) — Universidade Federal do Rio Grande do Norte, 2015.
- STINY, A. **'Battlefield MRI' in the works - Navy Times.** 2015. [Online; accessed 5-June-2024]. Disponível em: <<https://www.navytimes.com/news/your-navy/2015/06/04/battlefield-mri-in-the-works/>>.
- STOLFI, G.; CAMPOS, G. L. d. Processos de compressão de dados aplicados a imagens médicas. 2000.
- VEIKUTIS, V.; BRAZDZIUNAS, M.; KELERAS, E.; BASEVICIUS, A.; GRIB, A.; SKAUDICKAS, D.; LUKOSEVICIUS, S. Diagnostic approaches to adult-type diffuse glial tumors: Comparative literature and clinical practice study. **Current Oncology**, v. 30, n. 9, p. 7818–7835, 2023. ISSN 1718-7729. Disponível em: <<https://www.mdpi.com/1718-7729/30/9/568>>.
- ZIV, J.; LEMPEL, A. A universal algorithm for sequential data compression. **IEEE Transactions on information theory**, IEEE, v. 23, n. 3, p. 337–343, 1977.