

CLASSIFICAÇÃO SEMIAUTOMÁTICA DE FRATURAS VERTEBRAIS POR COMPRESSÃO EM IMAGENS DE RESSONÂNCIA MAGNÉTICA

L. Frighetto-Pereira*, R. M. Reis*, L. C. Pereyra*, P. M. Azevedo-Marques***, R. M. Rangayyan**, M. H. Nogueira-Barbosa*.

* Faculdade de Medicina de Ribeirão Preto - Universidade de São Paulo, Ribeirão Preto - SP, Brasil.

** Schulich School of Engineering, University of Calgary, Calgary-AB, Canada.

e-mail: lfplucas@usp.br

Resumo: Esse artigo apresenta o uso de técnicas de processamento de imagens para Diagnóstico Auxiliado por Computador (CAD) de fraturas vertebrais lombares por compressão (VCFs) em imagens de ressonância magnética (RM). Foram utilizadas imagens de RM obtidas na rotina clínica, no plano sagital, ponderadas em tempo de relaxação T1. Características de forma (área do corpo vertebral), de contraste (variação dos níveis de cinza do histograma) e de textura (14 atributos de Haralick) foram extraídas de 52 corpos vertebrais segmentados manualmente. A classificação dos padrões vertebrais foi feita utilizando-se um classificador não paramétrico do tipo KNN (*k-nearest neighbors*), com distância Euclidiana. O padrão de referência utilizado para testar o desempenho da classificação semiautomática foi uma classificação da presença ou ausência de fratura vertebral realizada por um radiologista experiente. Considerando um esquema de treinamento e testes com validação cruzada e dez repetições, obteve-se uma classificação correta de fratura vertebral de 82,69%.

Palavras-chave: corpos vertebrais, fraturas, ressonância magnética, reconhecimento de padrões.

Abstract: This paper presents the use of image processing techniques for Computer Aided Diagnosis (CAD) of vertebral compression fractures (VCFs) in magnetic resonance imaging (MRI). MR images obtained in the clinical routine in the sagittal plane, weighted relaxation time T1 have been used. Shape characteristics (area of the vertebral body), contrast (varying levels of gray histogram) and texture (Haralick 14 attributes) have been extracted from 52 manually segmented vertebral bodies. Classification of vertebral patterns was performed using a non-parametric classifier type KNN (*k-nearest neighbors*), with Euclidean Distance. The benchmark used to test the performance of semi-automatic classification was a classification of the presence or absence of vertebral fracture performed by an experienced radiologist. Considering a system of training and testing with cross-validation and ten repetitions, we obtained a correct classification of vertebral fracture of 82.69 %.

Keywords: vertebral bodies, fractures, magnetic resonance, pattern recognition.

Introdução

Fraturas compressivas dos corpos vertebrais não traumáticas em geral são secundárias às doenças que causam fragilidade óssea como a osteoporose e as metástases ósseas. Tanto as fraturas secundárias à osteoporose quanto as fraturas patológicas decorrentes de neoplasias malignas apresentam significativo impacto na qualidade de vida, no tratamento dos pacientes, e nos custos para o sistema de saúde, sendo particularmente comuns em idades mais avançadas.

Fraturas vertebrais compressivas secundárias às insuficiências ósseas da osteoporose frequentemente ocorrem de forma subclínica. De qualquer maneira as fraturas vertebrais secundárias a osteoporose constituem importante fator de predição de futuras fraturas da osteoporose e também estão relacionadas a aumento da mortalidade. As fraturas secundárias a metástases por sua vez podem representar o início dos sintomas de um paciente com neoplasia ou podem representar uma complicação em pacientes já diagnosticados da doença sistêmica. Qualquer que seja a etiologia das fraturas vertebrais compressivas a identificação precisa destas alterações é fundamental para o diagnóstico e para o tratamento dos pacientes. A Figura 1 ilustra uma imagem de ressonância magnética com ponderação em T1 da coluna vertebral contendo uma fratura vertebral em L1.

Desta forma é fácil entender o potencial impacto positivo do desenvolvimento de métodos diagnósticos precisos e reprodutíveis para as fraturas compressivas vertebrais, com o auxílio de técnicas computacionais.

KASAI *et al*, 2006 [1] descreveram um sistema automático de diagnóstico auxiliado por computador (CAD) para fraturas vertebrais a partir de imagens de radiografias em perfil do tórax. Aqueles autores obtiveram acurácia variando entre 70,9% e 76,6% quando comparado com a identificação de fraturas vertebrais baseada nas marcações manuais realizadas por radiologistas. RIBEIRO *et al*, 2012 [2] propuseram um CAD para auxílio na detecção de fraturas por compressão dos corpos vertebrais em radiografias de perfil da coluna lombar com sensibilidade de 78% e especificidade de 95%. AL-HELO *et al*, 2013 [3] desenvolveram um CAD para a detecção de fraturas de corpos vertebrais a partir de imagens de tomografia

computadorizada alcançando uma acurácia entre 93,2% e 98%.

Estes trabalhos tem em comum o desenvolvimento de CADs para detecção de fraturas vertebrais a partir de métodos que utilizam radiação ionizante, tanto em radiografias planas como em exames de tomografia computadorizada. Atualmente há uma necessidade reconhecida de minimizar a dose de radiação ionizante nos pacientes decorrente de procedimentos médicos. Além disto, sabe-se que as imagens de RM são eficientes na detecção precoce de fraturas [4] [5]. Nesse contexto, o estudo aqui apresentado visa explorar o uso de métodos de visão computacional e reconhecimento de padrões para o auxílio à detecção de fraturas de corpos vertebrais em imagens de ressonância magnética.




Figura 1: imagem de RM com ponderação em T1 ilustrando uma fratura vertebral por compressão em L1. Observe a diminuição da altura e deformidade relacionadas à fratura compressiva deste corpo vertebral (seta).

Materiais e métodos

Aquisição de imagem e pré-processamento - Foi utilizado um conjunto de imagens de pacientes atendidos no Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto da Universidade de São Paulo (HCFMRP-USP). O trabalho aqui apresentado foi aprovado em projeto de pesquisa submetido ao Comitê de ética em Pesquisa do Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto, sob parecer No 373.454 de 31/07/2013. Esse conjunto de imagens consiste de 30 imagens em formato JPEG, com 256 níveis de cinza (8 bits por pixel) com alguma Fratura Vertebral por Compressão (VCF), coletadas de 30 exames distintos de Ressonância Magnética com ponderação em tempo de relaxação T1 (Philips Achieva 1,5T MRI System, Philips Medical Systems, Best, The

Netherlands) com TE = 10ms, TR = 478ms e espessura de corte de 4mm de pacientes do HCFMRP-USP. Foram estudados os corpos vertebrais L1, L2, L3, L4 e L5. Antes da etapa de segmentação e pós-processamento das imagens, exames foram anonimizados, garantindo-se a privacidade dos pacientes. Uma segmentação manual dos corpos vertebrais de cada uma das 30 imagens dos exames foi realizada por um pesquisador treinado e com experiência prévia em segmentações manuais da anatomia da coluna vertebral em imagens de RM. Esse trabalho de segmentação manual gerou 30 imagens em formato JPEG com os respectivos contornos dos corpos vertebrais. No total, obteve-se um conjunto de dados de 150 corpos vertebrais, sendo 124 normais e 26 com fratura. Para se balancear o conjunto de amostras, foram escolhidos de forma aleatória 26 dos corpos vertebrais normais, totalizando, então, 52 corpos vertebrais, como apresentado na Tabela 1.

Tabela 1: Conjunto de corpos vertebrais utilizados no estudo

| | L5 | L4 | L3 | L2 | L1 | TOTAL |
|----------------|----|----|----|----|----|-------|
| NORMAL | 5 | 5 | 5 | 5 | 6 | 26 |
| FRATURA | 1 | 5 | 3 | 5 | 12 | 26 |
| TOTAL | 6 | 10 | 8 | 10 | 18 | 52 |

Softwares utilizados - A segmentação manual dos corpos vertebrais foi realizada utilizando-se o software Photoshop CS5TM [6]. O algoritmo de extração de característica dos corpos vertebrais foi desenvolvido no software MATLAB [7] e a classificação, validação e seleção de atributos foram realizadas utilizando o software de aprendizado de máquina WEKA [8].

Extração de atributos e classificação - A Tabela 2 mostra uma lista dos atributos que foram utilizados nesse trabalho.

Tabela 2: Lista de atributos

| Área do corpo vertebral em mm ² | |
|--|---|
| Estatística de Primeira Ordem | Coefficiente de variação do histograma |
| Atributos de textura de Haralick | <i>Energy</i> <i>Difference Moment</i> <i>Correlation</i> <i>Variance</i> <i>Inverse Difference Moment</i> <i>Sum of Squares: Average</i> <i>Sum of Squares: Variance</i> <i>Sum of Squares: Entropy</i> <i>Entropy</i> |

Difference Variance
Difference Entropy
Information Measures of Correlation1
Information Measures of Correlation2
Maximal Correlation Coefficient

Inicialmente, foram extraídos a média e desvio padrão do histograma de níveis de cinza de cada corpo vertebral, que são mensurações de estatística de primeira ordem. Porém, como atributo para o vetor de característica foi utilizado um coeficiente de variação, calculado pela razão entre desvio padrão e a média dos níveis de cinza do histograma de cada corpo vertebral. Os 14 atributos de textura de Haralick et al [9] foram também extraídos, calculando-se a matriz de co-ocorrência dos níveis de cinza de cada corpo vertebral utilizando as quatro possíveis direções de vizinhança (0, 45, 90 e 135 graus) e um pixel de distância ($d = 1$). Outra característica extraída foi a área do corpo vertebral em mm², somando um total de 16 atributos para cada amostra. Na Figura 1, é possível identificar a diferença de textura, do nível de cinza e da área do corpo vertebral L1 fraturado em relação aos demais corpos vertebrais lombares. Na região do platô superior de L1 na qual houve a fratura por compressão secundária a osteoporose, é visível a alteração da forma, acompanhada da redução de área do corpo vertebral, com diminuição da intensidade dos níveis de cinza e mudança da textura.

Para classificação dos corpos vertebrais foi utilizado o algoritmo de *k-nearest neighbor* (KNN), com $k=3$ e $k=5$, utilizando a distância Euclidiana para cálculo de similaridade, *10-fold cross-validation* como aprendizado supervisionado e estratégia de validação cruzado, sendo os corpos vertebrais com fratura considerados os casos positivos e os corpos vertebrais normais considerados negativos. Para esse estudo piloto foi escolhido o classificador KNN por se tratar de um classificador não paramétrico clássico, adequado para situações em que não se tem uma função de classificação previamente estabelecida e número de amostra restrito [10]. A classificação computacional foi comparada com o diagnóstico obtido a partir dos dados do prontuário eletrônico do paciente. Para ter maior consistência dos dados utilizados como padrão de referência, em todos os casos o diagnóstico da presença ou não de fratura vertebral obtido no prontuário eletrônico foi revisado por um radiologista especialista na avaliação de imagens da coluna vertebral e com mais de quinze anos de experiência nesta especialidade. Considerando que o diagnóstico presente no prontuário eletrônico foi inicialmente definido a partir de um processo de dupla leitura, que é o protocolo padrão da instituição de origem das imagens, cada amostra teve sua classificação confirmada por três radiologistas.

Os resultados foram medidos em porcentagem de acerto de classificação e pelo valor da área sob a curva ROC *Receiver Operating Characteristic* (AUROC).

Ambos obtidos a partir dos valores calculados para as medidas de sensibilidade e especificidade.

Seleção de atributos - Buscando-se melhorar o processo de classificação, bem como reduzir a dimensão dos vetores de atributos, foi realizada uma seleção a fim de se identificar os melhores atributos dos vetores de características para as classificações com $k=3$ e $k=5$. Para isso, o método *Wrapper* foi utilizado. Esse método avalia conjuntos de atributos usando um esquema de aprendizagem incremental. O processo de validação cruzada foi utilizado para avaliar a precisão do sistema de aprendizagem para cada conjunto de atributos [11]. Como método de busca utilizou-se o *BestFirst*, o qual realiza uma busca gulosa pelo primeiro melhor subconjunto de atributos do vetor de característica do corpo vertebral.

Resultados

Vetor completo - Os resultados da classificação utilizando o vetor de características completo (16 atributos) estão exibidos na Tabela 3. O desempenho da classificação global é indicado pela porcentagem de classificação correta de instâncias, as quais são 63,46% para $k=3$ e 61,54% para $k=5$. Para $k=3$, obteve-se uma AUROC = 0,707 e para $k=5$ AUROC = 0,663.

Tabela 3: Resultados da classificação para $k=3$ e $k=5$ utilizando o vetor característica completo.

| | k = 3 | k = 5 |
|------------------------------|--------------|--------------|
| Classificação correta | 63,46% | 61,54% |
| Sensibilidade | 0,538 | 0,538 |
| Especificidade | 0,731 | 0,692 |
| AUROC | 0,707 | 0,663 |

Seleção de atributos - A Tabela 4 mostra o resultado da seleção de atributos para $k=3$ e $k=5$. Os resultados da classificação utilizando a seleção de atributos do vetor de características estão exibidos na Tabela 5. O desempenho da classificação global é indicado pelas porcentagens de classificações corretas de instâncias, as quais são 82,69% para ambos classificadores. Para $k=3$, obteve-se uma AUROC=0,848 e para $k=5$ uma AUROC=0,851.

Tabela 4: Lista de atributos utilizados após a seleção de atributos para $k=3$ e $k=5$.

| KNN | Atributos selecionados |
|--------------|---|
| k = 3 | Área Coeficiente de variação Energy Variance Sum of Squares: Variance |
| k = 5 | Área Coeficiente de variação Energy Sum of Squares: Variance |

Tabela 5: Resultados da classificação para $k=3$ e $k=5$ utilizando a seleção de atributos.

| | k = 3 | k = 5 |
|------------------------------|--------------|--------------|
| Classificação correta | 82,69% | 82,69% |
| Sensibilidade | 0,808 | 0,808 |
| Especificidade | 0,846 | 0,846 |
| AUROC | 0,848 | 0,851 |

Discussão

Pode-se perceber nos resultados desse estudo piloto a grande diferença de desempenho dos classificadores quando se utiliza todos os atributos do vetor de características comparado com o vetor reduzido após a seleção de atributos. Há uma melhora de desempenho na classificação correta para $k=3$ de 63,46% com vetor característica completo para 82,69% após a seleção de atributos, ou seja, uma diferença de 19,23 pontos percentuais equivalentes a 23,3% de aumento. Para $k=5$, o desempenho na classificação correta foi de 61,54% com vetor característica completo para 82,69% após a seleção de atributos. Uma diferença de 21,15 pontos percentuais equivalentes 25,58% de aumento. Quanto à área sob a curva ROC (AUROC), houve uma variação de 70,7% para 84,8% após a seleção de atributos para $k=3$. Diferença de 14,7 pontos percentuais equivalentes a um aumento de 16,63%. Para $k=5$, a variação da AUROC foi de 66,3% para 85,1% após a seleção de atributos, uma diferença de 18,8 pontos percentuais equivalente a um aumento de 22,09%. Desta forma houve aumento da sensibilidade e da especificidade do método quanto à classificação. Foi realizado um teste para $k=1$, porém não se obteve resultados de classificação correta acima de 77%, tão pouco valores de AUROC acima de 74% para ambos os vetores características e, dessa forma, seus resultados não foram discutidos nesse trabalho. Quanto à seleção de atributos, nota-se a importância do atributo de área, do atributo estatístico de primeira ordem do histograma e dos atributos de textura de energia e os ligados à variância para a classificação de fraturas vertebrais. Os resultados preliminares apresentados são promissores para a classificação de fraturas compressivas de corpos vertebrais em imagens de ressonância magnética. Esse estudo é parte de um projeto mais amplo, onde o foco será a classificação de fraturas segundo sua etiologia devido à osteoporose (benignas) ou devido à presença de metástase ou tumores ósseos (malignas). Em complementação ao estudo aqui apresentado, estão em desenvolvimento métodos para segmentação automatizada dos corpos vertebrais e segmentação e classificação automatizadas dos discos intervertebrais, visando a construção de um aplicativo voltado para o auxílio ao diagnóstico médico (CAD) em lesões da coluna vertebral.

Agradecimentos

Nossos agradecimentos pelo apoio financeiro parcial do CNPq CAPES e FAPESP. Agradecemos aos membros do LaPIR (Laboratório de Processamento de Imagens e Informática Radiológica) do Centro de Imagens e Física Médica (CCIFM, Hospital das Clínicas da Faculdade de Medicina de Ribeirão Preto da Universidade de São Paulo).

Referências

- [1]Kasai S, Li F, Shiraishi J, Li Q, Doi K. Computerized detection of vertebral compression fractures on lateral chest radiographs: Preliminary results with a tool for early detection of osteoporosis. *Medical Physics*. 2006; 33(12):4664-4674.
- [2]Ribeiro E A, Nogueira-Barbosa MH, Rangayyan RM, Azevedo-Marques PM. Detection of Vertebral Compression Fractures in Lateral Lumbar X-ray Images. In: XXIII Congresso Brasileiro em Engenharia Biomédica – XXIII CBEB; Oct 2012; Porto de Galinhas, Brasil. 2012. P. 1136-1139.
- [3]Al-Helo S, Alomari RS, Ghosh S, Chaudhary V, Dhillon G, Al-Zoubi MB, Hiary H, Hamtini TM. Compression fracture diagnosis in lumbar: a clinical CAD system. *Int J CARS Springer*. 2013; 8:461–469.
- [4]Prasad D, Schiff D. Malignant spinal-cord compression. *Lancet Oncol*. 2005; 6:15-24.
- [5]Uetani M, Hashmi R, Hayashi K. Malignant and benign compression fractures: differentiation and diagnostic pitfalls on MRI. *Clinical Radiology*. 2004; 59:124-131.
- [6]Evening M. Adobe Photoshop CS5 for Photographers: a professional image editor's guide to the creative use of Photoshop for the Macintosh and PC. eBook; 2013.
- [7]The MathWorks, Inc. Image Processing Toolbox for use with Matlab®. Version 2; 1998.
- [8]Garner, Stephen R. et al. Weka: The waikato environment for knowledge analysis. In: Proceedings of the New Zealand computer science research students conference.; 1995. p. 57-64.
- [9]R. Haralick, K. Shanmugam, I. Dinstein. Textural features for image classification. *IEEE Transactions on Systems, Man and Cybernetics*. 1973; 3:610-621.
- [10]Shimo HK. Aplicação de filtros de Gabor para auxílio ao reconhecimento de padrões em doenças pulmonares difusas [Monografia]. Ribeirão Preto: Universidade de São Paulo; 2009.
- [11]Kohavi R, John GH. Wrappers for featuresubsetselection. *Artificial Intelligence*. 1997; 97(1-2):273-324.